

검증

거짓이 더 빨리 달리는 시대

팩트체크와 AI 자동화

허위정보가 무엇을 해치는가 · 팩트체크는 어떻게 하는가 · AI는 어디까지 돕는가

한국언론학회 2026 가을철 정기학술대회 · 시청자미디어재단 후원세션 발표

이종혁 · 경희대학교 미디어학과 · jonghxxx@khu.ac.kr · 2026. 9.

이 자료 보는 법

- 목차의 제목을 누르면 해당 슬라이드로 이동 · 각 쪽 오른쪽 위 ‘**목차** ⇐’로 복귀
- 파란 밑줄 용어 = 부록 용어·출처 사전으로 이동 · 번호는 쪽 하단 출처 목록과 대응
- 하단 출처의 링크 = 논문·보고서·기사 원문으로 바로 연결

목차

시작

· 표지	3
· 오늘의 흐름	4
· 한 장으로 보는 핵심	5

1부 · 허위정보는 무엇을 해치는가

· 용어부터 정확하게	6
· 거짓은 왜 더 빨리 달리나	7
· 세계 사례: 목숨·표·돈	8
· 한국 ① 선거 딥페이크	9
· 한국 ② 뉴스 이용과 신뢰	10
· 한국 ③ 건강: 가짜 처방·가짜 의사	11
· 한국 ④ 선거 음모론	12
· 해외 정치: 혐오와 폭력	13
· 역사 왜곡 ① 5·18	14
· 역사 왜곡 ② 참사·피해자 조롱	15
· 피해를 설명하는 공통 틀	16

2부 · 팩트체크란

· 팩트체크의 탄생과 확산	17
· 검증의 아홉 단계	18
· 숫자와 취지를 분리하기	19
· 팩트체크는 효과가 있나	20

3부 · 왜 자동화인가

· 사람만으로는 부족한 이유	21
· 자동 팩트체크의 흐름	22
· 핵심 기술: LLM과 RAG	23
· 기계의 일, 사람의 일	24

4부 · 세계의 자동 팩트체크

· 자동화의 발전 지도	25
· ClaimBuster와 ClaimCheck	26
· Squash가 남긴 교훈	27
· Full Fact AI (영국)	28
· Factiveverse (노르웨이)	29
· 기존 검증을 다시 쓰는 도구	30
· Der Spiegel · AI 커뮤니티 노트	31
· 이미지 조사 · 비교하는 법	32

5부 · 한국어 자동화

· 한국어로도 되는가	33
· 작동 방식	34
· 선별 모델 성능	35
· 토론에 적용한 결과	36
· 78.85%의 분모	37
· 실패에서 배우기	38
· 다음 단계: 에이전트	39
· 개선 과제 ① 고르기·모으기·판정	40
· 개선 과제 ② 운영·전달·평가	41

6부 · 평가

· 정확도 하나가 숨기는 것	42
· 국제 대회 AVeriTeC	43

7부 · AI의 한계와 통제

· AI 답변, 믿어도 되나	44
· AI가 틀리는 12가지 방식	45
· 딥페이크 탐지와 출처 증명	46

8부 · 제도와 생태계

· 한국의 검증 기반	47
· 국제 비교	48
· 한국에 필요한 설계	49

9부 · 시민의 검증법

· SIFT 네 동작	50
· 숫자 6질문 · 실제 예	51
· AI에게 제대로 묻기	52
· 신고와 도움	53

마무리

· 자주 받는 질문	54
· 맺으며	55

부록

· 용어·출처 사전 (원문 링크 95항목)	56
-------------------------	----

검증

거짓이 더 빨리 달리는 시대

팩트체크와 AI 자동화

허위정보가 무엇을 해치는가 · 팩트체크는 어떻게 하는가 · AI는 어디까지 돕는가

한국언론학회 2026 가을철 정기학술대회 · 시청자미디어재단 후원세션 발표

이종혁 · 경희대학교 미디어학과 · jonghxxx@khu.ac.kr · 2026. 9.

① **RAG (검색 증강 생성)** AI가 답하기 전에 웹·문서를 먼저 검색하고, 찾은 자료에 근거해 답하게 하는 방식임.
'기억으로 말하지 말고 자료 보고 말하라'는 지시와 같음. 자료를 붙여도 잘못 찾기·잘못 읽기·잘못 쓰기 오류는
남음. AVeriTeC 2025 대회 논문 (doi.org) ClaimCheck 논문(arXiv) (doi.org)

차례

오늘 발표의 흐름

문제 → 대응 → 자동화 → 한국어 사례 → 한계 → 제도 → 시민 실천 순서로 진행함

1

허위정보는 무엇을 해치는가

선거·건강·재산·집단 안전·피해자의 존엄까지 번지는 피해

2

팩트체크는 무엇이며 효과가 있는가

검증 9단계, 숫자와 취지 분리, 실험으로 확인된 효과

3

왜 자동화인가 · 세계의 자동 팩트체크

주장 탐지 → 기존 검증 매칭 → 근거 수집 → 예비 판정으로의 발전

4

한국어로도 되는가 — 연구 소개

대선 토론 3,919문장에 적용한 탐지·RAG 판정 시스템과 26개 개선 과제

5

평가·한계·제도

숫자 하나로 성능을 말하지 않는 법, AI의 실패 유형, 자원과 독립성

6

시민이 바로 쓰는 검증법

SIFT, 숫자 6질문, 신고 창구

요약

미리 보는 발표 핵심

질문	핵심 답
왜 지금 팩트체크?	허위정보가 선거·건강·재산·집단 안전·피해자 존엄까지 훼손함. 생성형 AI는 옛 음모론에 그럴듯한 음성·사진·신문 지면을 덧붙이는 수단
거짓이 더 빨리 퍼짐?	트위터 2006–2017 자료에서 거짓 뉴스가 더 빠르고 넓게 확산 — 특정 플랫폼·기간의 결과 Vosoughi 등 2018 ^①
세계 위험 순위?	WEF 2026 보고서에서 허위·조작정보는 향후 2년 위험 2위 — 위험 인식 조사임 WEF 2026 ^②
팩트체크 효과?	4개국 실험에서 잘못된 믿음 감소 확인. 다만 믿음 교정 ≠ 행동 변화 Porter & Wood 2021 ^③
AI는 어디까지?	한국어 팩트체크 자동화 연구에서 대선 토론 검증. JTBC와 일치율 78.85%. 훨씬 많은 검증 필요 문장 자동 탐지 이종혁 2026 ^④
현실적 목표?	검증할 주장을 더 넓게 찾고, 근거를 모아 팩트체크 도움. 공개 판정·반론·정정의 책임은 사람과 기관

① Vosoughi, Roy & Aral (2018), Science 트위터 2006–2017년 약 12만 6천 개 확산 사례 분석. 거짓 뉴스가 참 뉴스보다 더 멀리·빠르게·깊게 퍼졌고, 정치 분야에서 차이가 가장 컸음. 당시 트위터에서 판정 가능했던 사례에 한정된 결과. Science 논문 (DOI) (doi.org)

② WEF 글로벌 리스크 보고서 2026 세계경제포럼의 위험 인식 조사. 허위·조작정보는 향후 2년 위험 2위. ‘AI 기술의 부정적 결과’는 2년 30위 → 10년 5위. 실제 피해액 순위가 아니라 응답자 인식. Global Risks Report 2026 (weforum.org)

③ Porter & Wood (2021), PNAS 아르헨티나·나이지리아·남아공·영국 동시 실험, 22개 팩트체크 평가. 잘못된 믿음을 5점 척도에서 최소 0.59점 줄였고, 효과 대부분이 2주 넘게 유지. PNAS 논문 (DOI) (doi.org)

④ 이종혁 (2026), 한국언론학보 70(2) 「한국어 팩트체크 필요성 탐지 모델 및 RAG 기반 팩트체크 자동화 시스템 개발: 대선 후보자 토론회 적용」. 토론 3,919문장 → 499건 선별, JTBC 56건 중 52건 포착(92.86%), 공통 52건 판정 일치 41건(78.85%), 가중 F1 79.04%. DOI (doi.org) KCI 논문 정보 (kci.go.kr) 탐지 모델 (Hugging Face) (huggingface.co)

용어부터 정확하게

‘가짜뉴스’ 한 단어로 묶지 않음 — 내용의 진위와 유포 의도를 함께 봄 [Wardle & Derakhshan 2017](#)^①

용어	구분 기준	쉬운 예
오정보 misinformation	내용은 틀렸으나 속이려는 의도는 확인되지 않음	사실로 믿고 잘못된 건강 정보를 가족 단톡방에 전달
허위조작정보 disinformation	거짓·오도 내용을 고의로 제작·유포	상대 후보 발언을 조작해 실제 발언처럼 공개
악의적 정보 malinformation	실제 정보를 해칠 목적으로 사용	공익과 무관한 개인의 실제 사생활 유출
잘못된 맥락	실제 사진·영상에 다른 사건 설명을 부착	몇 년 전 홍수 사진을 “오늘 사고 현장”으로 공유
풍자·패러디	원래 맥락과 수용자의 이해가 관건	‘풍자’ 표시가 잘린 캡처가 사실 보도처럼 유통

- ❑ 옛 사진 + 거짓 설명 = 사진은 진짜여도 **주장은 거짓 맥락**. 의도는 별도 증거로 판단
- ❑ [인포데믹](#)^② = 감염병 유행 중 정보 과잉 현상 전체. 그 안에 거짓·오도 정보가 섞임
- ❑ 검증의 기본 = “어떤 문장이 어떤 근거와 충돌하는가”를 구체적으로 지적함

① 정보 무질서 (Wardle & Derakhshan, 2017) 유럽평의회 보고서. 오정보·허위조작정보·악의적 정보를 진위와 의도 두 축으로 구분한 대표 틀. [Council of Europe 보고서 \(PDF\)](#) (rm.coe.int)

② 인포데믹 (WHO) 감염병 유행 중 온·오프라인에서 정보가 지나치게 많아지는 현상. 그 안에 거짓·오도 정보가 섞여 혼란과 위험 행동을 부름. [WHO: Infodemic](#) (who.int)

1부 · 허위정보

거짓은 왜 더 빨리 달리나

12.6만

트위터 뉴스 확산 사례 분석 (2006–2017)
— 거짓이 더 빠르고 넓게 확산, 정치 분야에
서 차이 최대
[Vosoughi 등^①](#)

2위

WEF 2026: 향후 2년 세계 위험 중 허위·조
작정보 순위 (위험 인식 조사)
[WEF 2026^②](#)

30→5위

같은 보고서의 ‘AI 부정적 결과’: 2년 전망
30위 → 10년 전망 5위

생성형 AI의 위험

01 신원까지 위조

내용뿐 아니라 발원자·의사·언론사·
앵커라는 ‘권위의 얼굴’까지 합성함

02 옛 음모론의 새 포장

수십 년 된 주장에 새 ‘증거 사진’·‘당시
신문’을 붙여 재유통함

03 진짜도 부인

실제 녹음·영상도 “AI로 만든 것”이라며
부인하기 쉬워짐 — [거짓말쟁이의 배당^③](#)

① Vosoughi, Roy & Aral (2018), *Science* 트위터 2006–2017년 약 12만 6천 개 확산 사례 분석. 거짓
뉴스가 참 뉴스보다 더 멀리·빠르게·깊게 퍼졌고, 정치 분야에서 차이가 가장 컸음. 당시 트위터에서 판정 가능했던
사례에 한정된 결과. *Science* 논문 (DOI) ([doi.org](https://doi.org/10.1126/science.1257583))

② WEF 글로벌 리스크 보고서 2026 세계경제포럼의 위험 인식 조사. 허위·조작정보는 향후 2년 위험 2위. ‘AI
기술의 부정적 결과’는 2년 30위 → 10년 5위. 실제 피해액 순위가 아니라 응답자 인식. *Global Risks Report
2026* ([weforum.org](https://www.weforum.org/reports/global-risks-report-2026))

③ 거짓말쟁이의 배당 (liar’s dividend) 조작물이 흔해질수록 진짜 증거도 ‘AI 조작’이라며 부인하기 쉬워지는
현상임. Chesney·Citron이 제시한 개념. Chesney & Citron (2019) 논문 ([doi.org](https://doi.org/10.1146/annurev-lawsoftech-010419-025401))

세계 사례 — 목숨·표·돈을 노림

사례	확인된 사실	검증 포인트
이란 메탄올 중독 ❶ 2020	“술·소독제가 코로나 예방” 거짓 믿음 속 메탄올 중독 입원 5,876건, 법의학기관 집계 사망 800명	병원 사망 534명과 집계 범위가 다름. 800명 전원의 인과관계가 개별 입증된 것은 아님
인도 납치범 소문 ❷ 2018	WhatsApp ‘아동 납치범’ 소문 후 무고한 행인 집단폭행·사망 사건 잇따름	전달자의 선의가 사실 확인을 대신하지 못함
슬로바키아 조작 음성 ❸ 2023	선거 직전 야당 대표와 기자가 선거 조작을 논의하는 듯한 음성 유통, AFP가 조작 검증	공개 시점·원본 녹음·당사자 확인. 선거 결과 영향은 별도 연구 필요
바이든 사칭 자동전화 ❹ 2024	예비선거 직전 복제 음성으로 “투표 미루라” 유도. FCC 과징금 600만 달러	익숙한 목소리 ≠ 진짜 발신자. 선거 안내는 선거 당국 자료로 확인
홍콩 화상회의 사기 ❺ 2024	딥페이크 ‘재무책임자’ 화상회의에 속아 직원이 약 2억 홍콩달러 송금	송금 지시는 별도 연락 경로로 재확인

❶ **이란 메탄올 중독 (Critical Care, 2020)** 2020년 2월 23일–5월 2일 메탄올 중독 입원 5,876건, 법의학기관 집계 사망 800명(병원 내 사망 534명). 술·소독제가 코로나를 막는다는 거짓 믿음이 배경으로 지적됨. [Hassanian-Moghadam 등 \(2020\) \(doi.org\)](#)

❷ **인도 WhatsApp 납치범 소문 (2018)** 아동 납치범이 돌아다닌다는 WhatsApp 메시지 확산 후 무고한 행인들이 집단폭행당해 숨진 사건 잇따름. 2018년 7월 카르나타카 32세 남성 사망 사건 관련 25명 체포. [Reuters/Euronews 보도 \(euronews.com\)](#)

❸ **슬로바키아 선거 직전 조작 음성 (2023)** 총선 이틀 전, 진보슬로바키아 대표 미할 시메치카와 Denník N 기자 모니카 토도바가 선거 조작을 논의하는 듯한 음성 유통. AFP가 조작 징후를 검증. [AFP Fakty \(슬로바키아어\) \(fakty.afp.com\)](#)

❹ **FCC – 바이든 사칭 딥페이크 자동전화 (2024)** 뉴햄프셔 예비선거 직전 바이든 복제 음성으로 투표를 미루라고 유도한 자동전화. 2024년 9월 26일 FCC가 정치 컨설턴트에게 600만 달러 과징금 부과. [FCC 보도자료 \(PDF\) \(docs.fcc.gov\)](#)

❺ **홍콩 딥페이크 화상회의 사기 (2024)** 직원이 딥페이크로 꾸민 ‘본사 재무책임자’ 화상회의에 속아 약 2억 홍콩달러를 송금. 공개 영상으로 미리 만든 합성 자료 이용. [홍콩 정부 LCQ9 답변 \(info.gov.hk\)](#)

1부 · 한국의 징후

한국 ① — 하지 않은 말을 한 것처럼

10,319건

2026 지방선거 딥페이크 게시물 **삭제 요청** 누계 (5월 27일 기준) **경향신문** ①

10,510건

2025 대선 같은 성격 집계 (4.4–6.3) — 관측 기간이 달라 ‘증가율’ 계산에는 부적합

- ❑ **숫자 읽기:** 10,319 = 삭제 요청 건수. 제작자 수·독립된 허위 주장 수·삭제 완료 건수와 다름
- ❑ **가짜 앵커 영상** ②: “미국 시사주간지가 ○○ 예비후보 선정” 식 뉴스 형식 합성 — ‘보도 형식’을 빌린 권위 만들기
- ❑ **확인 순서:** ① 영상의 합성 여부 ② 후보 실제 업적 ③ 해당 매체 원문 존재 여부를 따로 확인
- ❑ **공직선거법** ③: 선거일 전 90일~선거일, 선거운동 목적 딥페이크의 제작·편집·유포·상영·게시 금지 — ‘모든 AI 사용 금지’는 아님

① **딥페이크 삭제 요청 1만 건 (경향신문, 2026.5.28)** 2026 지방선거 관련 딥페이크 게시물 삭제 요청 10,319건(5월 27일 기준). 2025 대선 4.4–6.3 집계 10,510건의 98.2% 수준. 기간이 달라 증가율 계산에는 부적합. [경향신문 기사 \(khan.co.kr\)](#)

② **AI 가짜 앵커·딥페이크와 선관위 (경향신문, 2026.5.25)** 예비후보를 해외 시사지가 선정했다는 식의 가짜 뉴스 앵커 영상 등, 대중화된 AI로 쉽게 만들어지는 선거 허위정보와 선관위 대응. [경향신문 기사 \(khan.co.kr\)](#)

③ **공직선거법 딥페이크 규정** 선거일 전 90일부터 선거일까지 선거운동 목적의 딥페이크 영상 등 제작·편집·유포·상영·게시 금지. 그 밖의 기간에도 가상정보 표시 의무, 허위사실 공표 규정 등 적용. [중앙선관위 보도자료 \(2025.4.23\) \(img.nec.go.kr\)](#)

1부 · 한국의 징후

한국 ② — 많이 보는 곳 ≠ 믿는 곳

로이터저널리즘연구소 **디지털 뉴스 리포트 2026**^① 한국 자료 — 이용·신뢰·우려는 서로 다른 질문의 응답

49%

유튜브로 뉴스 이용
(48개 시장 평균 31%)

30%

뉴스 전반 신뢰

59%

온라인 허위정보 우려

14%

AI 챗봇으로 뉴스 이용

- 온라인 설문 결과 — 전 국민 전수조사 값처럼 설명하지 않음
- 플랫폼 이용률만으로 ‘유튜브가 극단화를 일으켰다’는 결론 불가 — 기존 성향·추천 방식·이용 시간 분리 연구 필요
- 함의: 검증 결과도 **사람들이 실제로 머무는 곳**(영상·메신저·챗봇)으로 전달돼야 함

^① **디지털 뉴스 리포트 2026 — 한국** 로이터저널리즘연구소 온라인 설문. 한국 유튜브 뉴스 이용 49%(48개 시장 평균 31%), 뉴스 신뢰 30%, 온라인 허위정보 우려 59%, AI 챗봇 뉴스 이용 14%. 한국 파트는 한국언론진흥재단 연구진 집필. [Reuters Institute 한국 페이지](https://reutersinstitute.politics.ox.ac.uk) (reutersinstitute.politics.ox.ac.uk) [뉴스시스 보도](https://newsis.com) (newsis.com)

1부 · 한국의 징후

한국 ③ — 가짜 처방, 가짜 의사

2020 소금물 분무

성남 [은혜의강 교회](#) ①, “코로나 예방” 명목으로 교인 입에 같은 분무기로 소금물 분무. 방역당국은 감염 확산에 영향 줬을 가능성 지적

주의 집단감염의 모든 경로가 이 행위로 확정됐다는 서술은 피함

2026 AI 가짜 의사 광고

유튜브에 [AI로 만든 ‘의사’](#) ②가 식품 효능 홍보. 업체가 약 9개월간 약 65만 개 판매, 매출 81억 원 혐의로 수사

주의 81억 원 = 보도된 매출액. 법원이 확정된 피해액 아님

가운·청진기·방송 자막은 전문성의 증거가 아님

확인할 것 = 실존 인물·소속, 제품의 허가 용도와 근거. 치료 중단·약 변경 권유 영상은 담당 의료진과 상의

① 은혜의강 교회 소금물 분무 (2020) 성남 은혜의강 교회가 코로나 예방 명목으로 같은 분무기로 교인들 입에 소금물을 뿌린 사실 확인. 방역당국은 감염 확산 영향 가능성 지적. [연합뉴스 보도](#) (yna.co.kr)

② 유튜브 ‘AI 가짜 의사’ 광고 (서울신문, 2026.6.10) AI로 만든 의사가 식품 효능을 홍보. 업체가 약 9개월간 약 65만 개 판매, 매출 81억 원 혐의로 수사. 매출액이지 확정 피해액 아님. [서울신문 기사](#) (seoul.co.kr)

한국 ④ — ‘중국인 99명 체포’와 부정선거 의혹

사례 A 선거연수원 중국인 99명 체포설

2024년 12월 비상계엄 이후 “선거연수원에서 중국인 99명 체포” 주장 확산

- ❑ 선관위: 당시 숙박자는 교육 참여 공무원 88명 + 외부 강사 8명 = 96명
- ❑ 체포설은 전부 허위 [선관위 팩트체크](#) ①
- ❑ 검증 대상 = 숙박 기록·출입·체포 기록·관계기관 확인

사례 B 의혹이 계엄의 근거가 되나

헌법재판소 2025.4.4 탄핵 결정 [2024헌나8](#) ②

- ❑ 의혹이 있다는 것만으로 중대한 위기상황이 현실적으로 발생했다고 볼 수 없음
- ❑ 부정선거 의혹 = 정치적·제도적·사법적 수단으로 해결할 문제

의혹을 쪼개서 보기

보안 취약점 존재

≠

실제 침입

≠

투표 변경

≠

선거 결과 변경

① ‘선거연수원 중국인 99명 체포’ 선관위 팩트체크 당시 선거연수원 숙박자는 교육 참여 공무원 88명과 외부 강사 8명 등 총 96명. 체포설은 전부 허위라고 설명. 중앙선관위 팩트체크 (2025.1.23) ([nec.go.kr](#))

② 헌법재판소 2024헌나8 (2025.4.4) 대통령 탄핵 결정. 의혹이 있다는 것만으로 중대한 위기상황이 현실적으로 발생했다고 볼 수 없고, 부정선거 의혹은 정치적·제도적·사법적 수단으로 해결할 문제라고 판단. 헌법재판소 선고요지 ([ccourt.go.kr](#))

1부 · 세계 사례 · 정치

거짓 서사가 **폭력**으로 번질 때

C · 미국 2021 1·6 의회 공격

2020 대선 부정 주장 → 결과 뒤집기 시도 → 의회 공격의 경과를 하원 조사위 최종보고서가 정리 [최종보고서](#)^①

D · 영국 2024 사우스포트 이후 폭동

아동 살해 직후 “범인은 보트로 온 망명 신청자” 거짓 신원 확산 → 모스크·망명 신청자 숙소 공격 [하원 보고서](#)^②

E · 미국 2024 “이민자가 반려동물을 먹는다”

대선 토론에서 반복된 스프링필드 아이티 이민자 주장 — 현지 경찰·시 당국 확인과 불일치 [PolitiFact](#)^③

F · 뉴질랜드 2019 ‘대체’ 음모론과 테러

크라이스트처치 모스크 테러 — 왕립조사위가 백인우월주의·반이민 사상·온라인 급진화 맥락 검토 [왕립조사위](#)^④

① 미 하원 1·6 조사위원회 최종보고서 (2022) 2020 대선 부정 주장, 결과 뒤집기 시도, 2021년 1월 6일 의회 공격까지의 경과 정리. [최종보고서 \(PDF\)](#) (govinfo.gov)

② 영국 하원 내무위원회 — 2024 여름 소요 (2025.4.14) 사우스포트 아동 살해 직후 “범인은 망명 신청자”라는 추측·오정보가 온라인에서 폭력 선동에 중요한 역할을 했다는 내무부 설명 수록. 모스크·망명 신청자 숙소 공격 기록. 위원회는 허위정보가 소요의 구체적 동인이었던 정도는 불분명하다고도 지적. [HC 381 보고서](#) (publications.parliament.uk)

③ 스프링필드 ‘반려동물 먹는 이민자’ 주장 (PolitiFact) 2024 대선 토론에서 반복된 오하이오 스프링필드 아이티 이민자 주장 — 현지 경찰·시 당국에 신뢰할 만한 보고 없음. [PolitiFact 팩트체크](#) (politifact.com)

④ 크라이스트처치 모스크 테러 왕립조사위 (2020) 2019년 테러를 이해하기 위해 백인우월주의·반이민·반무슬림 사상·우익 극단주의·온라인 급진화 맥락 검토. [왕립조사위 보고서 해당 장](#) (christchurchattack.royalcommission.nz)

1부 · 역사 왜곡

기록을 바꾸고 희생자를 다시 공격 — 5·18

2026 AI로 만든 ‘1980년 신문’

1980년 5월 20일자 ‘광주일보’처럼 꾸민 합성 지면에 “북한군 투입·무기고 탈취” 주장. 20대 제작자 등 검거(수사 단계) [관련 보도](#) ^①

결정적 단서 ‘광주일보’ 제호는 1980년 12월 1일 언론 통폐합으로 처음 등장 — 1980년 5월에는 존재하지 않음

2023 ‘사진 속 시민 = 북한군’

5·18 사진 속 시민을 ‘북한 특수군’으로 지목한 지만원, 명예훼손 등으로 징역 2년 확정 [대법원 확정](#) ^②

5·18진상규명조사위(2024): 지만원의 ‘결정적 증거 42개’ 모두 사실무근 결론 — 사진 판독 오류·제한된 군사 지식 지적 [조사 결과](#) ^③

❑ 종이 질감·활자보다 **당시 제호·발행일·도서관 소장본** 대조가 더 강한 검증

❑ 역사 ‘의견’ 문제를 넘어 **실존 시민의 신원을 왜곡**해 명예를 훼손한 사건

① **5·18 왜곡 AI 가짜 신문** 1980년 5월 20일자 ‘광주일보’처럼 꾸민 합성 지면에 ‘북한군 투입·무기고 탈취’ 주장. 5·18기념재단 고소, 경찰이 20대 제작자 등 검거(수사 단계). ‘광주일보’는 1980년 12월 언론 통폐합으로 처음 발행된 제호. [연합뉴스 \(2026.5.27\)](#) (yna.co.kr) [뉴스시 \(2026.7.6\)](#) (newsis.com)

② **지만원 징역 2년 확정 (2023.1.12)** 5·18 사진 속 시민들을 ‘북한 특수군’으로 지목해 명예를 훼손한 혐의 등으로 대법원이 징역 2년 확정. [연합뉴스 보도](#) (yna.co.kr)

③ **5·18진상규명조사위 — 북한군 침투설 ‘허위’ (2024.4)** 지만원이 제시한 ‘결정적 증거 42개’를 검토해 모두 사실무근으로 결론. 사진 판독 오류와 제한된 군사 지식에 기댄 추론이라고 지적. [뉴스시 보도](#) (newsis.com)

참사 피해자·약자를 조롱하는 거짓

사례	내용
참사 피해자 공격 ^① 2026.5	세월호·이태원·제주항공 참사 희생자·유족 겨냥 허위·모욕 글 약 3천 건 게시한 50대 구속
‘위안부’ 피해 부정 ^② 2026.6.11 시행	개정 위안부피해자법: 허위사실 유포 최대 징역 5년·벌금 5천만 원. 예술·학문·연구·보도 등 정당한 목적은 예외
샌디훅 부정론 ^③ 미국	“총기 참사는 연출” 주장한 알렉스 존스 — 배심원 9억 6,500만 달러 + 판사 약 4억 7,300만 달러 추가. 2024 항소심, 평결 유지·1억 5천만 달러 부분 파기
홀로코스트와 AI ^④	UNESCO: 생성형 AI가 없는 사건·인용을 만들거나 부정론 증폭 경고. 아우슈비츠 기념관: AI 생성 ‘희생자 이미지’ 확산 문제 제기
로힝야·르완다·스레브레니차 ^⑤	유엔 조사기구: 미얀마 군 연계 Facebook 혐오 네트워크 분석. 르완다·구유고 국제재판소: 선동 미디어 책임·집단학살 판단

① [참사 피해자 겨냥 허위글 3천 건 \(2026.5\)](#) 세월호·이태원·제주항공 참사 희생자·유족을 겨냥한 허위·모욕 글 약 3천 건을 올린 50대 구속. 한 피의자에 대한 수사 내용. [뉴스시스 보도](#) (newsis.com)

② [개정 위안부피해자법 \(2026.6.11 시행\)](#) 일본군 ‘위안부’ 피해 허위사실 유포에 최대 징역 5년 또는 벌금 5천만 원. 예술·학문·연구·보도 등 정당한 목적의 활동은 처벌 제외. [정책브리핑 \(성평등가족부\)](#) (korea.kr)

③ [샌디훅 부정론 — 알렉스 존스 배상](#) 2022년 코네티컷 배심원 9억 6,500만 달러 평결, 판사가 약 4억 7,300만 달러 추가. 2024년 12월 항소법원은 평결을 유지하고 1억 5천만 달러(CUTPA) 부분만 파기. [Connecticut Public \(2022\)](#) (ctpublic.org) [AP/Connecticut Public \(2024\)](#) (ctpublic.org)

④ [홀로코스트 기억과 생성형 AI](#) UNESCO: 생성형 AI가 존재하지 않는 사건·인용을 만들거나 부정론을 증폭할 위험 경고. 아우슈비츠 기념관: AI 생성 수용소·희생자 이미지 확산 문제 제기. [UNESCO \(2024\)](#) (unesco.org) [Auschwitz Memorial report 2025 \(PDF\)](#) (auschwitz.org)

⑤ [로힝야·르완다·스레브레니차](#) 유엔 미얀마 독립조사기구: 군 연계 Facebook 혐오 네트워크 분석. 르완다 국제형사재판소(2003): 미디어 책임자들의 집단학살 관련 유죄. 구유고 국제형사재판소(2004): 크르스티치 항소심에서 스레브레니차 집단학살 확인. [IIMM 분석 보고서](#) (iimm.un.org) [ICTR ‘미디어 재판’](#) (unictr.irmct.org) [ICTY 크르스티치 항소심](#) (icty.org)

1부 · 정리

피해를 설명하는 공통 틀

피해	반복되는 방식	필요한 대응
민주적 판단 훼손	발언 위조, 투표 절차 거짓 안내, 근거 없는 결과 부정	원영상·회의록·선거 자료 확인, 입증할 주장 분리
생명·건강 침해	치료 효능 과장, 가짜 의사, 검증 안 된 예방법	임상 근거·허가 범위·실존 전문가 확인
재산 피해	가족·상사·금융기관 사칭	별도 연락 경로, 송금 승인 절차
집단에 대한 공격	범인 신원을 이민자·소수자로 오인시키기	신원 확인 수준 명시, 집단 일반화 차단
존엄·기억 훼손	피해자를 사기꾼으로, 사진 속 인물 신원 바꾸기, 사료 위조	기록 대조, 피해자 보호, 신속 정정·신고

공통점 = **그럴듯한 형식**(뉴스 화면·의사 가운·옛 신문·익숙한 목소리)이 증거처럼 작동함 → 형식이 아니라 **원기록**을 확인해야 함

2부 · 팩트체크

언론의 기사 확인에서 **공개 검증**으로

기사 속 이름·날짜 확인(내부 검증, 게이트키퍼)과 이미 퍼진 발언·소문을 독자에게 설명하는 팩트체크는 다른 활동

03

2003 · 미국 FactCheck.org 출범

정치인 발언을 공개적으로 검증하는 전문 매체 등장 [FactCheck.org](#)¹

07

2007 · PolitiFact 출범 → 2009 풀리처상

‘진실 측정기’ 등급 체계로 대중화 [PolitiFact](#)²

17

2017.3.29 · SNU팩트체크 출범

12개 언론사로 시작 → 약 30개 제휴사, 약 5천 건 검증 축적. 2023년 서울에서 GlobalFact 10 공동 개최 [관련 보도](#)³

24

2024.8.18 · SNU팩트체크 무기한 휴지

재원 중단. 기존 자료는 읽기 전용으로 유지

핵심은 팩트체크 등급 판정이 아니라 “독자가 확인 과정을 따라갈 수 있고, 새 근거가 나오면 고칠 수 있음”

¹ **FactCheck.org** 2003년 출범한 미국 비영리 팩트체크 매체. 검증 절차를 공개하고, Meta 제3자 팩트체크 제휴(2016.12~2025.4) 내역도 명시. [15주년 글 \(2018\)](#) ([factcheck.org](#)) [검증 절차 \(Our process\)](#) ([factcheck.org](#))

² **PolitiFact** 2007년 출범. ‘진실 측정기(Truth-O-Meter)’ 등급으로 유명하며 2009년 풀리처상 수상. [풀리처상 수상 \(2009\)](#) ([politifact.com](#))

³ **SNU팩트체크 (2017~2024)** 2017년 3월 29일 12개 언론사와 출범, 약 30개 제휴사·약 5천 건 검증 축적. 2023년 GlobalFact 10 서울 공동 개최. 재원 중단으로 2024년 8월 18일부터 무기한 휴지, 기존 자료는 읽기 전용. [오마이뉴스 보도 \(2024.8.19\)](#) ([ohmynews.com](#))

2부 · 팩트체크

검증의 아홉 단계

FactCheck.org 공개 절차와 **IFCN 원칙**^①을 작업 순서로 재구성 — 기관마다 명칭은 다름

1 주장 선정

공익성·확산·예상 피해 고려. 의견·가치판단은 제외

2 원문 확보

최초 영상·전체 발언·게시일·앞뒤 맥락 보존

3 검증 단위 분리

수치·비교·인과·예측을 나눔

4 주장자에게 근거 요청

출처와 의도 확인

5 원자료 수집

통계 원표·법령·판결문·논문·회의록

6 반대 근거 탐색

처음 추정을 뒤집을 자료도 찾음

7 전문가·당사자 확인

자료 해석과 반론 검토

8 판정·편집 검토

결론이 근거보다 세지 않은지 점검

9 공개·이의·정정

수정 내용·이유·시점 기록

IFCN 5대 약속 = 비당파성·공정성, 출처 투명성, 자원·조직 투명성, 방법론 투명성, 공개적이고 정직한 정정. 인증은 무오류 보증이 아님

^① IFCN 원칙 강령 국제팩트체킹네트워크의 5대 약속: 비당파성·공정성, 출처 투명성, 자원·조직 투명성, 방법론 투명성, 공개적이고 정직한 정정. [IFCN Code of Principles \(ifcncodeofprinciples.poynter.org\)](https://ifcncodeofprinciples.poynter.org)

2부 · 연습

숫자와 취지를 분리하기

교육용 가상 사례 — “두 공항은 철도로 연결되어 있고 이동에는 10분 걸립니다.”

공식 시간표상 해당 구간 소요시간이 38분이라고 가정

하위 주장	판단
두 공항이 철도로 연결됨	확인 가능
역 사이 이동시간 10분	공식 시간표와 충돌 (38분)
두 공항이 가까움	평가 기준·목적에 따라 달라짐

- ❑ ‘가깝다는 취지는 맞다’는 이유로 틀린 숫자(10분)까지 참이 되지 않음
- ❑ 한 문장 = 여러 하위 주장 → 쪼개서 각각 판정하는 것이 자동화 시스템 설계의 출발점이기도 함
- ❑ 판정 척도도 구분: 원래 **LIAR**¹ 6등급에는 ‘pants-fire’가 있고 ‘판단 유보’는 없음

¹ **LIAR 판정 척도** PolitiFact 기사로 만든 연구용 데이터셋의 6등급: true, mostly-true, half-true, barely-true, false, pants-fire(새빨간 거짓말). ‘판단 유보’ 등급은 없음. 이종혁(2026)은 이를 응용해 판단 유보를 포함한 6단계 사용.


팩트체크는 효과가 있나

4개국 동시 실험

아르헨티나·나이지리아·남아공·영국, 22개 팩트체크 사용 [Porter & Wood 2021](#)^①

- ❑ 잘못된 사실 믿음을 5점 척도에서 **최소 0.59점** 개선
- ❑ 효과 대부분이 2주 뒤에도 유지
- ❑ 뚜렷한 역효과 관찰 안 됨 — ‘어떤 조건에서도 없다’로 확대하지 않음

‘효과’는 여러 층



“효과 있다” 뒤에는 반드시 **무엇의 효과인지** 붙임

생태계: 성장과 위축의 공존

437개

전 세계 팩트체크 프로젝트 (2026.6.1, 116개국·70개 언어) [Duke Reporters' Lab](#)^②

441→437

2025년 말 대비 감소 — 자원 압박 속 감소세

2025

Meta 미국 제휴 종료(FactCheck.org 2016.12–2025.4), Google 검색

[ClaimReview](#)^③ 표시 정리 — 서로 별개 변화

① **Porter & Wood (2021), PNAS** 아르헨티나·나이지리아·남아공·영국 동시 실험, 22개 팩트체크 평가. 잘못된 믿음을 5점 척도에서 최소 0.59점 줄였고, 효과 대부분이 2주 넘게 유지. [PNAS 논문 \(DOI\)](#) (doi.org)

② **Duke Reporters' Lab 2026 팩트체크 센서스** 2026년 6월 1일 기준 116개국·70개 언어 437개 프로젝트 활동. 2025년 말 441개에서 감소 — 자원 압박 속에서도 대부분 존속. [2026 census](#) (reporterslab.org)

③ **ClaimReview** 팩트체크 대상 주장과 검증 결과를 기계가 읽을 수 있게 적는 구조화 데이터 형식임. 2025년 Google이 검색 결과 표시를 정리했지만, 형식 자체나 팩트체크 기사가 폐지된 것은 아님. [Google Search Central 블로그 \(2025.6\)](#) (developers.google.com)

3부 · 왜 자동화인가

사람만으로는 따라잡기 어려움

대선 토론 3회만 해도 수천 문장 — 무엇을 먼저 검증할지 고르는 일부터 병목 **이종혁 2026**^①

토론 3회 전체 문장

3,919

AI가 ‘검증 필요’로 선별

499

JTBC 팩트체크 사례

56

❑ $499 - 56 = “443건 방치”$ 라고 말할 수 없음 — 오탐·중복·검증 단위·기자의 선정 기준이 다름

❑ 그러나 후보를 넓게 찾아 주는 것만으로도 기자의 선택지를 넓힘

자동화의 실익 = ‘진실 기계’가 아니라 시간 절약

① 검증 후보 찾는 시간 ② 반복 주장 알아보는 시간 ③ 근거 모으는 시간을 줄여, 사람이 판단·취재·반론 청취에 집중하게 함

^① 이종혁 (2026), 한국언론학보 70(2) 「한국어 팩트체크 필요성 탐지 모델 및 RAG 기반 팩트체크 자동화 시스템 개발: 대선 후보자 토론회 적용」. 토론 3,919문장 → 499건 선별, JTBC 56건 중 52건 포착(92.86%), 공통 52건 판정 일치 41건(78.85%), 가중 F1 79.04%. DOI (doi.org) KCI 논문 정보 (kci.go.kr) 탐지 모델 (Hugging Face) (huggingface.co)

3부 · 자동화의 구조

자동 팩트체크는 6단계 파이프라인

1

수집 — 방송·기사·게시물

음성은 전사(받아쓰기), 영상은 프레임 추출

2

주장 추출·분할

문장을 나누고 한 문장 속 여러 주장을 분리

3

검증 후보 선정 claim detection

“검증할 가치가 있는 사실 주장인가” 점수화 — **ClaimBuster**^①의 핵심 기능

4

기존 검증·원자료 검색 claim matching · RAG

과거 팩트체크와 매칭, 웹·위키·통계·법령 검색

5

근거 정리와 예비 판정

지지·반박 근거 연결, 판정 초안 — 근거 부족하면 **판단 유보**^② → 4단계로 재검색

6

사람 검토·공개·정정

최종 문구·반론·공개 여부·정정 책임은 사람과 기관

① **ClaimBuster** (텍사스대 알링턴) 토론·연설 문장의 ‘검증 가치’를 점수화한 선구적 시스템. 2017년 논문은 모니터링 → 검증 가치 평가 → 기존 검증 매칭 → 검증·보고의 end-to-end 구조 제시. Hassan 등 (2017) 논문 (doi.org)

② **판단 유보** 근거·맥락이 충분하지 않을 때 결론을 보류하는 기능임. ‘모름’을 숨기지 않고 왜 모르는지(검색 실패·자료 비공개·출처 충돌)를 밝히는 것도 검증의 일부.

핵심 기술 — LLM과 RAG

LLM^①

대규모 언어모델. 학습한 지식으로
답하고, 검색·DB·문서를 ‘도구’로 받아
쓸 수도 있음

+

검색 (웹·위키·기사 저장소)

답하기 전에 관련 자료를 먼저 찾음.
외부 웹뿐 아니라 기관 내부 기사
저장소도 가능

=

RAG^②

찾은 자료를 근거로 답을 생성 —
“기억으로 말하지 말고 자료 보고
말하라”

RAG를 붙여도 남는 오류 세 가지

① 잘못 찾음

엉뚱한 문서·요약 블로그만 회수

② 잘못 읽음

맞는 문서를 찾기도 조건·단위를 놓침

③ 잘못 씀

인용과 결론이 어긋남, 없는 출처 생성
(환각^③)

“LLM은 학습 이후 일을 전혀 모른다”는 설명은 부정확 — 도구 없는 모델과 검색 연결 시스템을 혼동한 것

① **LLM (대규모 언어모델)** 방대한 글로 학습해 문장을 이해·생성하는 AI(예: ChatGPT, Gemini, Claude)임. 학습한 지식으로 답하기도 하고, 검색·데이터베이스를 도구로 연결해 최신 자료를 읽기도 함.

② **RAG (검색 증강 생성)** AI가 답하기 전에 웹·문서를 먼저 검색하고, 찾은 자료에 근거해 답하게 하는 방식임. ‘기억으로 말하지 말고 자료 보고 말하라’는 지시와 같음. 자료를 붙여도 잘못 찾기·잘못 읽기·잘못 쓰기 오류는 남음. AVerITeC 2025 대회 논문 (doi.org) ClaimCheck 논문(arXiv) (doi.org)

③ **환각 (hallucination)** 자료에 없는 내용·출처·인용문을 사실처럼 지어내는 오류임. 존재하지 않는 판결·논문·URL 생성이 대표적. 대응 = 실제 본문·DOI·인용 위치 대조.

기계의 일, 사람의 일

시스템이 제공할 것	사람이 판단할 것
원문과 발언 시점	검증 대상으로 삼을 공익적 이유
동일·유사 주장 후보	인물·지역·기간이 실제로 같은지
지지·반박 근거와 인용 위치	출처의 이해관계, 자료 해석, 반론의 타당성
판정 초안과 유보 사유	공개 문구, 정정, 피해 구제와 책임
검색·수정 기록	절차의 공정성과 설명 가능성

근거 부족은 거짓의 증거가 아님

‘검색 실패’, ‘원자료 비공개’, ‘출처 충돌’, ‘주장 자체 불명확’을 한꺼번에 ‘거짓’으로 처리하지 않음

문장 고르기에서 근거 수집·판정까지

앞 단계가 사라진 것이 아니라 기능이 차곡차곡 쌓여 온 역사

① 주장 탐지 — 수많은 문장 중 확인할 문장 고르기

ClaimBuster

② 기존 검증 매칭 — 반복 발언에 과거 팩트체크 연결

Squash · Full Fact · Meedan

③ 기사 저장소 기반 답변 — 검증 기사로 대화형 응답

Fátima · Snopes FactBot

④ 외부 근거 + 예비 판정 — 검색해 결론 초안 작성

ClaimCheck · AVeriTeC · 한국어 연구

⑤ 편집·공개 전 점검 — 자사 원고 오류 경보

Der Spiegel

⑥ 시민 협업 — AI가 설명 제안, 사람이 평가

X AI Community Notes

초기부터 ‘끝에서 끝까지(end-to-end)’ 자동화를 구상한 연구가 있었고, LLM 이전에도 실시간 팩트체크 표시가 구현됨 [Hassan 등 2017^①](#) · [Adair 2021^②](#)

① **ClaimBuster (텍사스대 알링턴)** 토론·연설 문장의 ‘검증 가치’를 점수화한 선구적 시스템. 2017년 논문은 모니터링 → 검증 가치 평가 → 기존 검증 매칭 → 검증·보고의 end-to-end 구조 제시. [Hassan 등 \(2017\) 논문 \(doi.org\)](#)

② **Squash (Duke Reporters’ Lab)** 연설을 실시간 전사하고 관련 팩트체크를 찾아 화면에 띄운 시스템. 전사 오류·엉뚱한 매칭·비교할 기존 검증 부족이 주요 장애물. [Poynter 회고 \(2021\) \(poynter.org\)](#)

4부 · 대표 시스템

원조 ClaimBuster, 최신 ClaimCheck

미국 · 2017 ClaimBuster^①

토론 문장의 ‘검증 가치’를 점수화한 시스템으로 유명. 논문은
모니터링 → 검증 가치 평가 → 기존 검증 매칭 → 검증·보고의 전체
구조까지 제시

문장	처리
“더 나은 미래를 만들겠습니다.”	포부·약속
“어제 점심을 먹었습니다.”	사실이지만 공익 우 선순위 낮음
“지난해 청년실업률은 10%였습니다.”	검증 대상 지 역·기간·연령 정의 확정

미국 · 2025 ClaimCheck^②

작은 공개 모델(Qwen3-4B) + 웹 검색



- ❑ 저자 보고 AVeriTeC 자료 정확도 76.4%
- ❑ 공식 대회의 ‘결합 점수’ 33.17과 다른 지표
- ❑ 프리프린트 — 상용 환경 성능으로 확대하지 않음

① ClaimBuster (텍사스대 알링턴) 토론·연설 문장의 ‘검증 가치’를 점수화한 선구적 시스템. 2017년 논문은
모니터링 → 검증 가치 평가 → 기존 검증 매칭 → 검증·보고의 end-to-end 구조 제시. Hassan 등 (2017) 논문
(doi.org)

② ClaimCheck (2025, 프리프린트) 작은 공개 모델 Qwen3-4B와 웹 검색을 결합. 검색 계획 → 근거 수집 →
종합 → 추가 검색 → 판정. 저자 보고 AVeriTeC 자료 정확도 76.4%. arXiv 논문 (doi.org)

4부 · 대표 시스템

TV 화면에 팩트체크를 띄운 Squash

Duke Reporters' Lab — 연설 음성을 문자로 바꾸고, 관련 팩트체크를 찾아 실시간으로 화면에 표시 [개발 회고 2021](#)^①

장애물 1 전사 오류

음성 인식이 틀리면 뒤 단계 전부 흔들림

장애물 2 엉뚱한 매칭

비슷한 단어를 쓴 무관한 주장끼리 연결

장애물 3 비교할 검증 부족

새 발언과 맞출 기존 팩트체크 자체가 모자람

교훈

매칭 시스템 성능 = 모델 성능 × 이미 검증해 둔 지식의 양 × 화면 설계. 사람이 잘못된 매칭을 걸러 내는 편집 도구 추가. “방금 나온 문장의 새 검증인가, 비슷한 과거 발언의 검증인가”도 구분 표시 필요

① Squash (Duke Reporters' Lab) 연설을 실시간 전사하고 관련 팩트체크를 찾아 화면에 띄운 시스템. 전사 오류·엉뚱한 매칭·비교할 기존 검증 부족이 주요 장애물. [Poynter 회고 \(2021\)](#) (poynter.org)

4부 · 대표 시스템

영국 Full Fact AI — 모니터링에서 예비 분석으로

33만

평일 하루 처리 문장 수 (기관 공개 운영 규모) [Full Fact](#) ^①

30개국

40개 이상 기관이 도구 이용

136건

2026 영국 선거: 이미지·영상 16,514건
중 SynthID 흔적 추정 [Nieman Lab](#) ^②

- ❑ **활용 사례:** 긴 팟캐스트 속 백신 허위정보 구간 찾기, 전립선암 검진 연구의 잘못된 보도 포착 → 정정 유도
- ❑ **현재 제품:** 정확성에 대한 AI 예비 판정 + 100점 만점 위해 점수 제공 [제품 페이지](#) ^③
- ❑ **2026 선거:** 스코틀랜드·웨일스 의회, 잉글랜드 시장 선거 후보 관련 계정 1천여 개 모니터링
- ❑ 136건 = 모두 허위정보라는 뜻도, AI 생성물을 빠짐없이 찾았다는 뜻도 아님 — [SynthID](#) ^④는 특정 도구의 워터마크 단서
- ❑ 예비 판정 기능이 있어도 사람 검토 없이 기사로 공개한다는 뜻은 아님

① **Full Fact AI (영국)** 평일 약 33만 문장 처리, 30개국 40개 이상 기관 이용(2025 공개). 반복 주장 탐지, 팟캐스트 속 허위정보 구간 찾기, 잘못된 보도 포착 → 정정 유도. [How AI can help fact checkers \(2025\)](#) ([fullfact.ai](#)) [Full Fact AI 홈](#) ([fullfact.ai](#))

② **Full Fact의 2026 선거 대응 (Nieman Lab)** 스코틀랜드·웨일스 의회, 잉글랜드 시장 선거 후보 관련 계정 1천여 개 모니터링. 이미지·영상 16,514건 중 SynthID 흔적으로 보이는 136건 발견. [Nieman Lab \(2026.6.25\)](#) ([niemanlab.org](#))

③ **Full Fact AI 제품 기능** 정확성에 대한 AI 예비 판정과 100점 만점 위해 점수 등을 설명. 예비 판정 기능 = 사람 검토 보조. [제품 페이지](#) ([fullfact.ai](#))

④ **SynthID** Google이 자사 AI 생성물에 넣는 보이지 않는 워터마크임. 찾으면 해당 도구 사용의 단서가 되지만, 다른 도구로 만든 AI 콘텐츠는 잡지 못함.

4부 · 대표 시스템

노르웨이 Factiveverse — 실시간·다국어

사례	내용	읽는 법
덴마크 Tjekdet 2024	토론 실시간 검증: 전사 → 주장 탐지 → 다중 검색. 음성 경로가 영상 스트림보다 최대 30초 빠름 회고 ^①	미래 발언 예측이 아님. 전사 정확도 약 95%는 Tjekdet 편집장 평가
스웨덴 SVT 2026	유튜브 등 정치 콘텐츠 모니터링 → 편집자에게 요약 제공 사례 글 ^②	‘하루 120시간’ = 개발사가 추정한 선거기 정치 영상 규모
헝가리 총선 2026	주요 정당·후보 진영 5곳의 영상 62개에서 1시간 30분 이내 2,528개 주장 추출·분석 분석 글 ^③	개발사 보고 — 2,528건 판정 정확도의 독립 검증은 아님

의미

모르는 언어의 선거도 **한두 시간 안에 주장 지도**를 그리는 수준까지 도달. 다만 운영 사례는 가능성을 보여 줄 뿐, 공통 벤치마크 평가를 대신하지 못함

① Factiveverse × 덴마크 Tjekdet (2024) 토론 실시간 검증: 전사 → 주장 탐지 → 다중 검색. 음성 경로가 영상 스트림보다 최대 30초 빠름(개발사). 전사 정확도 약 95%는 Tjekdet 편집장의 평가. Factiveverse 회고 (factiveverse.ai)

② Factiveverse × 스웨덴 SVT (2026) 유튜브 등 정치 콘텐츠를 모니터링해 편집자에게 요약 제공. ‘하루 120시간’은 개발사가 추정한 선거기 정치 영상 규모. Factiveverse 사례 글 (factiveverse.ai)

③ Factiveverse 헝가리 총선 분석 (2026) 주요 정당·후보 진영 5곳의 영상 62개에서 1시간 30분 이내 2,528개 주장 추출·분석(개발사 보고). Factiveverse 분석 글 (factiveverse.ai)

4부 · 대표 시스템

이미 한 검증을 다시 쓰는 도구들

아르헨티나 Chequeabot^①

발언·보도에서 검증 후보 발굴, 기자의 선정 지원. 전사 시간 90% 감소 보고 — ‘판정 정확도 90%’ 아님

미국·국제 Meedan Check^②

메신저 제보 수집, 유사 주장·이미지 대조. 2019 인도 총선 Checkpoint 제보 창구에 사용

브라질 Aos Fatos · Fátima^③

자사 검증 기사 기반 챗봇 응답. 초기 시험 답변 94% 적절 — 운영자 설명

미국 Snopes FactBot^④

Cal Poly와 공동 개발. Snopes 기사 자료를 대화형으로 검색 — 답의 범위는 보유 기사로 제한

장점

검증된 기사로 범위를 좁혀 출처 통제 쉬움, 반복 주장에 즉시 대응

한계

기사 자체의 오류·오래된 정보·아직 안 다룬 주장은 공백. 과거 검증의 대상·시점·조건 변화 확인 필요

① **Chequeabot (Chequeado, 아르헨티나)** 발언·보도에서 검증 후보를 찾고 기자의 선정을 도움. 전사 시간 90% 감소 등 보고. [Poynter 기고 \(2024\)](#) ([poynter.org](#))

② **Meedan Check** 메신저 제보 수집, 유사 주장·이미지 대조로 검증 작업·회신 지원. 2019 인도 총선 Checkpoint 프로젝트에 사용. [Meedan #TechAndCheck 2020](#) ([meedan.com](#))

③ **Fátima (Aos Fatos, 브라질)** 자사 검증 기사에 기반해 질문에 답하는 챗봇. 초기 시험 답변 94% 적절(운영자 설명). [Aos Fatos: Fátima](#) ([aosfatos.org](#)) [Nieman Lab \(2024\)](#) ([niemanlab.org](#))

④ **Snopes FactBot** Cal Poly와 Snopes가 공동 개발. Snopes 기사 자료를 대화형으로 검색해 답함. [Cal Poly 발표 \(2024\)](#) ([calpoly.edu](#))

4부 · 새로운 적용

편집국 안으로, 시민 곁으로

독일 · 2024 베타 Der Spiegel^①

자사 원고의 사실 주장 추출 → 웹 등 자료 확인 → 신뢰도 점수·경보
→ 사람의 후속 검토

- ❑ 베타 단계 실험 — 전사적 완성 배치 아님
- ❑ 인물명·날짜·직책·수치 점검은 외부 음모론 판정과 다른 업무

X · 2025-2026 AI 작성 Community Notes^②

AI 계정이 노트 초안 작성, 사람이 평가

7.4%

전체 423,915개 중 AI 노트
31,464개

18.0%

‘도움됨’ 도달률 (인간 8.9%)

- ❑ ‘도움됨’ ≠ 정확도 — 평가자 합의 지표
- ❑ AI와 사람이 같은 게시물에 무작위 배정된 시험 아님
- ❑ 생산량 증가 ≠ 믿음·공유 감소

① **Der Spiegel AI 팩트체크 (2024 베타)** 자사 원고의 사실 주장 추출 → 자료 확인 → 신뢰도 점수·경보 → 사람 후속 검토. 베타 단계 실험. [ONA 사례 연구 \(journalists.org\)](https://journalists.org)

② **AI 작성 Community Notes (R Street, 2026)** 2025.9-2026.3 노트 423,915개 중 활동 AI 계정 24개가 쓴 31,464개(7.4%). ‘도움됨’ 도달률 AI 18.0%, 인간 8.9%. [R Street 보고서 \(rstreet.org\)](https://rstreet.org)

이미지 조사 도구와 비교의 질문

Google DeepMind Backstory¹

이미지의 맥락·과거 사용·생성/편집 단서를 함께 조사하는 실험 도구. 2026년 8월 보도 시점 신뢰 테스터 한정 제공. 기자 시험에서 기자 본인 사진을 다른 기자로 오인한 사례 → 가장 오래된 검색 결과 ≠ 실제 최초 게시, 폐쇄형 메신저 이력은 누락 가능

비교 질문	확인할 조건
기존 검증을 잘 찾나?	주장 의미·인물·지역·시점 일치
새 주장의 근거를 잘 모으나?	핵심 원자료와 반대 근거 회수
판정이 맞나?	누가 만든 정답인가, 등급 정의가 같은가
기사로 공개해도 되나?	반론·저작권·개인정보·피해 위험 검토
실무에 도움 되나?	사람의 총 작업시간·수정 부담 감소 여부

¹ Backstory (Google DeepMind) 이미지의 맥락·과거 사용·생성/편집 단서를 조사하는 실험 도구. 2026년 8월 보도 당시 신뢰 테스터에게만 제공. 기자 시험에서 기자 본인 사진을 다른 기자로 오인한 사례 보고. DeepMind 블로그 (deepmind.google) Nieman Lab (2026.8.19) (niemanlab.org)

한국어로도 되는가

한국어 ‘검증 필요 문장 탐지’와 ‘RAG 기반 판정’을 하나로 연결해 제21대 대선 후보자 토론회 3회에 적용

이종혁 (2026). 한국어 팩트체크 필요성 탐지 모델 및 RAG 기반 팩트체크 자동화 시스템 개발: 대선 후보자 토론회 적용^①

한국언론학보 70(2), 86–123 · DOI 10.20879/kjcs.2026.70.2.003 · 탐지 모델 공개: Hugging Face [jonghxxx/claim_factcheck](https://huggingface.co/jonghxxx/claim_factcheck)^②

3,919

분석한 토론 문장

499

자동 선별 (12.7%)

92.86%

JTBC 검증 56건 중 포착 52건

78.85%

공통 52건 중 판정 일치 41건

기여

탐지 → 검색 → 판정을 잇는 **한국어 전 과정 시스템**을 실제 선거 토론에 적용하고, 기자 검증과 비교해 가능성과 한계를 함께 공개함

① 이종혁 (2026), 한국언론학보 70(2) 「한국어 팩트체크 필요성 탐지 모델 및 RAG 기반 팩트체크 자동화 시스템 개발: 대선 후보자 토론회 적용」. 토론 3,919문장 → 499건 선별, JTBC 56건 중 52건 포착(92.86%), 공통 52건 판정 일치 41건(78.85%), 가중 F1 79.04%. DOI (doi.org) KCI 논문 정보 (kci.go.kr) 탐지 모델 (Hugging Face) (huggingface.co)

② [jonghxxx/claim_factcheck](https://huggingface.co/jonghxxx/claim_factcheck) 이종혁(2026) 연구의 한국어 검증 필요 문장 탐지 모델 공개 페이지임. Hugging Face 모델 페이지 (huggingface.co)

시스템은 이렇게 작동함

1

문장 분리

공개 토론 속기록 → 3,919문장 (음성 인식까지 포함한 실시간 평가와는 다름)

2

검증 필요성 탐지

[KcELECTRA](#) ^① 기반 모델, 번역한 [CLEF CheckThat!](#) ^② 자료로 학습

3

근거 수집

일반 웹 검색 + 한국어 위키백과 + 검색 API — 검색 품질이 결과를 좌우

4

판정

[LangGraph](#) ^③ 작업 흐름 + Gemini 2.5 Flash

5

출력

판정 + 근거 설명 + 참조 자료

판정 6단계

참

대체로 참

절반의 참

대체로 거짓

거짓

판단 유보

[LIAR](#) ^④ 계열 다단계 판정을 응용하되 ‘판단 유보’를 새로 포함 — 원래 LIAR 라벨 체계와 동일하지 않음

① **KcELECTRA** 네이버 뉴스 댓글 등 구어체 한국어로 학습한 공개 언어모델임. 이종혁(2026)의 ‘검증 필요 문장’ 탐지 모델의 기반. [Hugging Face: KcELECTRA](#) ([huggingface.co](#))

② **CLEF CheckThat!** 유럽 CLEF 학회의 자동 팩트체크 공동과제임. 검증 가치 탐지, 숫자·시간 주장 검증, 팩트체크 기사 생성 등을 다룸. 이종혁(2026)은 이 자료를 번역해 탐지 모델 학습에 사용. [CheckThat! 2026 개요](#) ([arXiv](#)) ([doi.org](#)) [CheckThat! Lab 홈페이지](#) ([checkthat.gitlab.io](#))

③ **LangGraph** 여러 AI 작업 단계(검색 → 정리 → 판정 → 재검색)를 흐름도처럼 연결해 실행하는 개발 도구임. [LangGraph \(GitHub\)](#) ([github.com](#))

④ **LIAR 판정 척도** PolitiFact 기사로 만든 연구용 데이터셋의 6등급: true, mostly-true, half-true, barely-true, false, pants-fire(새빨간 거짓말). ‘판단 유보’ 등급은 없음. 이종혁(2026)은 이를 응용해 판단 유보를 포함한 6단계 사용.

5부 · 성능 ①

“검증할 문장인가” 고르는 성능

89.31%

정확도

전체 시험 문장 중 분류를 맞춘
비율

92.05%

정밀도 ①

‘검증 필요’로 고른 것 중 실제
양성

75.00%

재현율 ②

실제 검증 필요 문장 중 찾아낸
비율

82.65%

F1 ③

정밀도·재현율의 조화평균

쉽게 말하면

고른 것은 대체로 정확(정밀도 높음), 다만 시험 자료 속 검증 대상
4개 중 1개는 놓침(재현율 75%)

주의

이 표는 **문장 선별 성능** — 사실 여부를 맞힌 정확도가 아님. 모든
실제 토론에서 꼭 25%를 놓친다는 뜻도 아님


① 정밀도 (precision) 시스템이 ‘검증 필요’라고 고른 것 중 실제로 맞은 비율임. 높을수록 헛짚는 일이 적음.

② 재현율 (recall) 실제 검증이 필요한 문장 중 시스템이 찾아낸 비율임. 75%면 4개 중 1개를 놓친 셈.

③ F1 점수 정밀도와 재현율의 조화평균임. 한쪽만 높고 다른 쪽이 낮으면 F1이 낮아져 균형을 보여 줌.

5부 · 성능 ②

대선 토론 499건의 자동 판정



총계 보면

근거가 부족할 때 무리하게 단정하지 않음 — 사람에게 넘길 사안을 표시

과제

유보 원인이 검색 실패·자료 부족·맥락 해석 실패 중 무엇인지 분리해야 실제 성능 평가 가능. **유보가 많다 ≠ 안전한 시스템**

78.85%는 몇 건 중 몇 건인가



비교 항목	계산	말해 주지 않는 것
JTBC 사례 포착률	52 ÷ 56 = 92.86%	토론 속 중요한 모든 주장을 92.86% 찾았다는 뜻 아님
공통 사례 판정 일치율	41 ÷ 52 = 78.85%	499건 전체의 정확도 아님
공통 사례 가중 F1	79.04%	모든 분야·모델·시점의 보편 성능 아님

JTBC 결과 = 비교 기준. 등급 경계·주장 단위·기준 시점 차이로도 불일치 가능 → 사람보다 우월함을 입증한 비교가 아님

활용 전에 분석할 실패

문제	필요한 후속 분석
기자가 다뤘으나 놓친 4건	문장 분리·탐지·맥락 중 어느 단계 누락인지
공통 52건 중 불일치 11건	숫자 오류·출처 충돌·등급 경계·기준 시점 차이
유보 219건	검색 실패·정보 부재·접근 제한·결론 충돌 분리
인용 보도를 근거로 오인	“누가 말했다” vs “그 말이 사실이다” 구별
시점 오류	발언 후 수정된 통계를 당시 통계처럼 사용했는지
<u>지식 누출</u> ¹	기존 팩트체크 기사·모델의 학습 기억으로 답을 가져왔는지
분야 일반화	의학·지역선거·재난·이미지 주장에서도 작동하는지

모든 오류가 이 유형이었다는 단정이 아니라, 평가 범위를 넓힐 때의 **점검 목록**

¹ 시간적 누출 · 지식 누출 평가 시점 이후에 나온 자료나 정답 기사(기존 팩트체크)가 검색·학습에 섞여 성능을 부풀리는 문제임. 시험 문제를 미리 본 것과 같은 효과. CLEF CheckThat! 2026 개요 (doi.org)

다음 단계 — 역할을 나눈 AI 에이전트

한 모델이 다 하는 대신, 수집·판정·검토를 나눠 서로 견제하게 하는 구조 (발표자 개발 중인 방향)

역할	하는 일	막으려는 오류
수집	검색 질문 생성, 근거 문서 확보	같은 기사의 복제본을 독립 근거로 세는 오류
판정	근거와 하위 주장 연결, 결론 초안	출처에 없는 내용 덧붙이기
검토	인용·논리·시점·반대 근거 점검	앞 에이전트 판단을 그대로 따라가기
사람	반론·최종 문구·공개 여부 결정	자동화 편향 ^① , 책임 공백

참고 Full Fact AI 해커톤 (2026.3)

하루 동안 초기 조사·편집 지침 점검 등 시제품 12개 제작 [Full Fact 블로그](#)^② — 시제품 ≠ 검증된 제품

① 자동화 편향 사람 검토자가 그럴듯한 AI 초안을 충분히 따져 보지 않고 승인하는 경향임. 대응 = 일부 사례 독립 재검토, 반증 담당 지정, 정정 기록.

② Full Fact AI 해커톤 (2026.3) 하루 동안 초기 조사, 편집 지침 점검 등 AI 시제품 12개 제작. Full Fact AI 블로그 (fullfact.ai)

6개 영역 26개 과제 ① — 1~14

I 무엇을 고를까

- 1 한국어 원문 학습 자료 확대, 분야 구성비 공개
- 2 숫자·시간 주장은 별도 경로로 단위·계산 검사
- 3 ‘작년’은 발언 날짜 확인 후 연도로 변환
- 4 앞뒤 발언·화자 유지, 의견·농담 제외

II 근거를 어떻게 모을까

- 5 실시간·사후 검증 분리, 사후 자료는 날짜 표시
- 6 주장에 맞는 출처 선택 (통계=원표, 법=법령·판결)
- 7 검색 요약 말고 본문·표·주석 확보
- 8 사실 확인 자료 vs 단순 전달·예정 보도 구분
- 9 같은 보도자료 재인용 묶기, 상충 근거 보존

III 어떻게 판정할까

- 10 사실마다 근거 위치 연결, 인용 내용 일치 확인
- 11 참·거짓 방향과 유보 사유 먼저, 세밀 등급은 사람
- 12 복합 주장 분해, 부분 참을 전체 참으로 확장 금지
- 13 ‘좋은 취지’로 틀린 수치 구제 금지
- 14 반대 근거 찾는 독립 검토, 다수결 ≠ 사실

6개 영역 26개 과제 ② — 15~26

Ⅳ 어떻게 운영할까

- 15 기존 팩트체크 먼저, 시점·대상·조건 변화 검사
- 16 쉬운 일·어려운 일에 다른 모델, 비용·지연·오류 비교
- 17 에이전트 수·재검색 상한, 사람 이관 규칙
- 18 대량은 정해진 흐름, 충돌·유보만 추가 조사
- 19 실시간 경보와 공개 자막 분리, 미검증 결론 자동 방송 금지

Ⅴ 어떻게 전달할까

- 20 유보 원인 + 다음 행동 제안
- 21 근거·반론 포함 기사 초안, 편집 검토 통과
- 22 검색어·채택 자료·기준일·판정 이유 공개
- 23 AI 사용·사람 검토·수정 내역·이의 창구 공개

Ⅵ 어떻게 평가할까

- 24 평가 후 자료·정답 기사 복제본 혼입 통제 (시간적 누출^①)
- 25 선별·검색·판정 성능 따로, 화자·주제별 차이
- 26 근거 부족 단정률, 거짓→참 공개율, 유보 해결률 보고

숫자·시간 주장 검증, 전체 팩트체크 기사 생성은 CLEF CheckThat! 2026^②의 정식 과제 — 세계 연구의 최전선과 같은 방향

① **시간적 누출 · 지식 누출** 평가 시점 이후에 나온 자료나 정답 기사(기존 팩트체크)가 검색·학습에 섞여 성능을 부풀리는 문제임. 시험 문제를 미리 본 것과 같은 효과. [CLEF CheckThat! 2026 개요](#) (doi.org)

② **CLEF CheckThat!** 유럽 CLEF 학회의 자동 팩트체크 공동과제임. 검증 가치 탐지, 숫자·시간 주장 검증, 팩트체크 기사 생성 등을 다룸. 이종혁(2026)은 이 자료를 번역해 탐지 모델 학습에 사용. [CheckThat! 2026 개요](#) (arXiv) (doi.org) [CheckThat! Lab 홈페이지](#) (checkthat.gitlab.io)

‘정확도’ 하나가 숨기는 것

예: 문장 대부분이 검증 대상이 아니면, 전부 ‘대상 아님’으로 찍어도 정확도는 높게 나옴 → 놓친 비율(재현율)을 함께 봐야 함

단계	질문	지표·방법
수집	중요한 채널·발언을 놓치지 않았나	수집 범위, 전사 오류, 누락 분석
주장 분리	원문 의미·조건을 보존했나	경계·화자·맥락 보존 평가
선별	검증할 주장을 찾았나	정밀도, 재현율, 위해 가중 누락률
검색	필요한 자료를 찾았나	근거 회수율, 원자료 접근, 날짜 적합성
근거 연결	인용이 결론을 뒷받침하나	인용 충실성, 지지·반박 적합성
판정	자료에 맞는 등급인가	클래스별 F1, <u>혼동행렬</u> ❶, 오판 사례
불확실성	자신감과 실제 성능이 맞나	<u>보정</u> ❷, 유보율
운영	사람 작업량이 줄었나	건당 비용·시간, 수정량
사회적 효과	이용자 판단이 나아졌나	사전등록 실험, 공유·행동 추적

❶ 혼동행렬 실제 범주와 예측 범주의 조합별 결과표임. ‘거짓을 참으로’ 같은 치명적 오판이 몇 건인지 드러남.

❷ 보정 (calibration) 시스템이 말하는 확신도와 실제 정답 빈도가 맞는 정도임. ‘90% 확신’한 답이 실제로 90% 맞아야 잘 보정된 것.

세계 대회 AVeriTeC의 33.17

4,568

50개 팩트체크 기관이 다룬 현실 주장 + 웹
근거 [AVeriTeC 2023](#) ^①

33.17

2025년 2회 대회 7개 시스템 중 최고 점수
[Akhtar 등 2025](#) ^②

23GB · 1분

공개 가중치 모델, 단일 GPU 메모리 23GB,
주장당 평균 1분 이내 조건

33.17 = “사실을 맞힐 확률 33%”가 아님

판정이 맞고 근거 품질도 기준을 충족해야 점수로 인정되는 결합 지표 — 근거 없이 맞힌 답은 인정 안 됨

- ❑ 제공된 지식 저장소 사용 — 자유 웹 검색·대형 상용 모델과 조건이 다름
- ❑ 한국 연구진의 [HerO](#) ^③가 공식 기준 시스템으로 활용됨
- ❑ 보고 원칙: 자료의 언어·기간·분야, 정답 제작 절차, 모델·프롬프트·검색 시점, 유보 처리, 비용·시간 공개
- ❑ ‘정확도’, ‘도움됨’, ‘결합 점수’, ‘믿음 교정’은 서로 다른 지표 — 하나의 AI 순위표로 묶지 않음

① **AVeriTeC (2023)** 50개 팩트체크 기관이 다룬 현실 주장 4,568개와 웹 근거로 구성된 평가 자료. 인위적 문장 평가의 한계를 줄이려는 목적. [NeurIPS 논문 \(DOI\)](#) (doi.org)

② **제2회 AVeriTeC 공동과제 (FEVER 2025)** 공개 가중치 모델·단일 GPU 23GB·주장당 평균 1분 이내 조건. 7개 제출 중 최고 33.17 — 판정과 근거 품질을 함께 충족해야 인정되는 결합 점수. HerO 효율화 버전이 기준 시스템. [Akhtar 등 \(2025\)](#) (doi.org)

③ **HerO** 한국 연구진(송실대)이 개발한 공개 자동 팩트체크 시스템임. 2025년 AVeriTeC 대회에서 계산 효율화 버전이 공식 기준 시스템으로 쓰임. [GitHub: HerO](#) (github.com) [AVeriTeC 2025 대회 논문](#) (doi.org)

AI에게 물으면 믿어도 되나

응답 품질 EBU·BBC 2025^①

18개국 22개 공영미디어, 14개 언어, AI
응답 3천여 건

- ❑ **45%** 중대한 문제 1개 이상
 - ❑ **31%** 심각한 출처 문제
 - ❑ **20%** 주요 정확성 문제
- 항목 중복 가능 — ‘45%가 거짓’ 아님

이용자 믿음 DeVerna 등 2024^②

미국 2,159명 · 정치 헤드라인 40개 실험

- ❑ ChatGPT 팩트체크 → 진위 식별력
유익한 개선 없음
- ❑ 인간 팩트체크 → 개선
- ❑ 당시 모델 결과 — 최신 AI 전체로
일반화 금지

SNS 봇 “@Grok 이거 사실?”^③

X의 Grok·Perplexity 사실확인 요청

150만여 건 분석 (프리프린트)

- ❑ 표본 판정 일치: Grok 54.5%,
Perplexity 57.7%
- ❑ 팩트체커끼리 일치 64.0%

세 결과는 모두 참일 수 있음

응답 품질 · 판정 일치 · 믿음 변화는 서로 다른 질문에 대한 답

① EBU·BBC AI 뉴스 답변 국제 조사 (2025) 18개국 22개 공영미디어, 14개 언어, 3천여 응답 평가. 45% 중대한 문제 1개 이상, 31% 심각한 출처 문제, 20% 주요 정확성 문제. EBU 발표 (ebu.ch)

② DeVerna 등 (2024), PNAS 미국 2,159명, 정치 헤드라인 40개 실험. LLM 팩트체크는 진위 식별력을 유의하게 높이지 못했고 일부 조건에서 오히려 해침. 인간 팩트체크는 개선. PNAS 논문 (DOI) (doi.org)

③ “@Grok is this true?” (Renault 등, 2026) X에서 Grok·Perplexity에 요청된 사실 확인 150만여 건과 실험 분석. 표본 게시물 판정 일치: Grok 54.5%, Perplexity 57.7%, 팩트체커 간 64.0%. 동료 심사 전 프리프린트. PsyArXiv (DOI) (doi.org)

AI 팩트체크가 틀리는 방식

실패	구체적 모습	대응
검색 실패	원표 대신 요약 블로그만 인용	원자료 경로 검색, 확보 실패 표시
시간 오류	2026 수정 통계를 2022 발언에 적용	발언일·자료 기준일·검색일 구분
단위·계산	억↔조, %↔%p 혼동	계산식·단위 별도 검사
맥락 손실	‘아니다’·조건절 삭제	전후 문장·원영상 연결
인용 오인	“A가 X라 말했다”를 X의 증거로	발언 사실과 내용 진위 분리
출처 복제	같은 보도자료 기사 10개 = 증거 10개	원출처로 묶기
권위 편향	‘공식 발표’라서 반대 근거 배제	이해관계·독립 검증 확인
환각 ^①	없는 판결·논문·인용 생성	본문·DOI·인용 위치 대조
자료 오염	허위 페이지가 검색 상위 점유	최초 출처·게시 이력 확인
과잉 교정	농담·의견에 거짓 등급	검증 가능한 주장인지 먼저 판단
자동화 편향 ^②	그럴듯한 초안을 그대로 승인	독립 검토·반증 담당
과신	근거 빈약한데 단정	유보 규칙·공개 승인 기준

① 환각 (hallucination) 자료에 없는 내용·출처·인용문을 사실처럼 지어내는 오류임. 존재하지 않는 판결·논문·URL 생성이 대표적. 대응 = 실제 본문·DOI·인용 위치 대조.

② 자동화 편향 사람 검토자가 그럴듯한 AI 초안을 충분히 따져 보지 않고 승인하는 경향임. 대응 = 일부 사례 독립 재검토, 반증 담당 지정, 정정 기록.

탐지기·워터마크가 말해 주는 것과 못 하는 것

확인 결과	말할 수 있는 것	말할 수 없는 것
유효한 C2PA ^① 서명	서명 주체와 일부 제작·편집 이력	게시물 설명·정치적 주장이 사실임
AI 워터마크 탐지	해당 도구의 생성·편집 흔적 단서	모든 AI 사용 탐지, 기만 의도 확정
역이미지 검색의 과거 사진	같은 이미지의 이전 사용	더 오래된 원본이 없다는 것
탐지기 ‘AI 가능성 높음’	해당 모델의 분류 결과	법적·역사적 사실의 최종 확정

- ❑ 출처 이력이 없거나 지워졌다고 가짜가 되는 것도 아님
- ❑ 손가락 수·입 모양 같은 결함만으로 판단하지 않음 — 최초 게시자·원본·시간·장소·기관 기록·독립 보도를 함께 봄

공개 전 사람의 역할

위험이 클수록 검토를 무겁게: 일정·기초 자료 조회는 표본 점검, **선거 부정·질병 치료·금융 사기**는 담당자의 실질 검토, 폭력 선동·신상 정보는 경보·보존·기관 대응 우선. 출처·근거 문장 공개, AI 사용 표시, 정정·이의 경로, 수정 이력 보존

^① **C2PA · Content Credentials** 사진·영상의 제작·편집 이력을 전자서명으로 붙여 전달하는 국제 표준임.
이력의 무결성은 확인하지만, 사진 속 사건이나 설명의 진실은 보장하지 않음. 이력이 없다고 가짜도 아님. **C2PA**
[FAQ \(c2pa.org\)](#) [C2PA 설계 원칙 \(c2pa.org\)](#)

한국의 검증 기반 — 재원이 끊기자 멈춤

2024.8.18 SNU팩트체크 휴지^①

네이버·해외 공익재단 지원으로 운영 → 재원 중단으로 무기한 휴지. 기존 자료는 읽기 전용 유지

지원 종료·정치적 비판·운영 중단은 각각 확인할 사실 — 특정인의 직접 지시라는 인과는 같은 수준으로 확인된 것 아님

2023.2 팩트체크넷 해산^②

법인 해산·플랫폼 운영 중단 (국회입법조사처 자료)

다른 조직·사업이지만 같은 과제: **지속적 재원 + 운영 독립성**의 동시 설계

개정 정보통신망법^③ — 2026.1.6 공포 · 7.7 시행 · 가이드라인 7.8 배포

구분	핵심 내용
가중 손해배상	요건 충족한 수익형 게재자의 고의 허위조작정보 → 손해액 최대 5배. 모든 잘못된 게시물에 자동 적용 아님
과징금	판결 확정 정보를 2회 이상 유통한 수익형 게재자 → 최대 10억 원
대규모 플랫폼	자율 운영정책, 신고·처리·통지·이의신청, 정기 보고
팩트체크 협약	국제 규범 준수 단체와 협약을 체결할 수 있음 (의무 아님)
독립성·남용 방지	지원 이유로 검증 대상·결과 개입 금지, 정당한 비판 봉쇄 청구 대응 절차

① SNU팩트체크 (2017–2024) 2017년 3월 29일 12개 언론사와 출범, 약 30개 제휴사·약 5천 건 검증 축적. 2023년 GlobalFact 10 서울 공동 개최. 재원 중단으로 2024년 8월 18일부터 무기한 휴지, 기존 자료는 읽기 전용. 오마이뉴스 보도 (2024.8.19) (ohmynews.com)

② 국회입법조사처 — 2023 국정감사 이슈 분석 팩트체크넷의 2023년 2월 법인 해산·플랫폼 운영 중단 경과 등 수록. 국회입법조사처 자료 (PDF) (shinkim.com) 국회입법조사처 홈 (nars.go.kr)

③ 정보통신망법 가이드라인 (2026.7.8) 개정법 2026.1.6 공포, 7.7 시행. 수익형 게재자 가중배상 최대 5배, 과징금 최대 10억 원, 대규모 플랫폼 의무, 팩트체크 단체와 협약 체결 가능, 독립성·남용 방지 규정. 방송미디어통신위원회 가이드라인 (kmcc.go.kr)

다른 나라는 어떻게 하나

사례	제도·경과	한국에 던지는 질문
EU 행동강령 ¹	2025.2 DSA 체계 통합 승인, 7.1부터 약속 감사 가능	삭제 건수 너머 시스템 위험·투명성을 평가하나?
EU 독립 검증 지원 ²	2026.3 500만 유로. EFCSN FACTEUR 30개월 사업, 60% 초과를 팩트체크 기관에 배분	지원자와 편집 결정 사이 거리 확보 방법은?
OECD ³	정보원 투명성·다원성, 사회적 회복력, 거버넌스 통합 접근	표현의 자유와 정보 접근을 함께 보호하나?
일본 JFC ⁴	모기관과 회계 분리, 수입·지출·후원자 공개	의존도·잔여 자원·정정까지 공개하나?
싱가포르 POFMA ⁵	장관의 정정 지시 + 취소 신청·고등법원 불복 절차	행정 판단과 사법 통제를 어떻게 배치하나?
호주 ⁶	2024.11.24 상원 지지 부족으로 허위정보 법안 추진 중단	권한 범위·표현의 자유 합의 가능한가?

2,617만¥ JFC 2025 회계연도 수입	3,348만¥ 지출	731만¥ 부족액 — 이월금으로 충당	2,167만¥ Google·LY·Meta·IFCN 보조금 합계
-----------------------------	---------------	-------------------------	---------------------------------------

¹ **EU 허위정보 행동강령** 2025년 2월 DSA(디지털서비스법) 체계의 행동강령으로 통합 승인, 7월 1일부터 약속 이행 감사 가능. [European Commission](#) ([digital-strategy.ec.europa.eu](#))

² **EU 독립 팩트체크 500만 유로 지원 (2026)** 유럽 민주주의의 방패 차원의 지원. EFCSN의 FACTEUR는 30개월 사업, 60% 초과 금액을 팩트체크 기관에 배분. [European Commission 발표](#) ([digital-strategy.ec.europa.eu](#)) [EFCSN FACTEUR](#) ([efcsn.com](#))

³ **OECD, Facts not Fakes (2024)** 정보 무결성을 위한 통합 접근: 정보원의 투명성·책임성·다원성, 사회적 회복력, 제도와 거버넌스. [OECD 보고서 \(DOI\)](#) ([doi.org](#))

⁴ **일본 팩트체크센터 (JFC) 재원 공개** 2025 회계연도(2025.4~2026.3) 수입 26,172,407엔, 지출 33,478,977엔, 부족액 7,306,570엔은 이월금으로 충당. Google·LY·Meta·IFCN 보조금 합계 21,673,341엔. [JFC funding and budget](#) ([factcheckcenter.jp](#))

⁵ **싱가포르 POFMA** 장관이 정정 등 지시를 내리는 구조. 변경·취소 신청과 고등법원 불복 절차 존재. [POFMA Office FAQ \(PDF\)](#) ([pofmaoffice.gov.sg](#))

⁶ **호주 허위정보 법안 철회 (2024.11.24)** 상원 지지를 확보하지 못해 허위정보 관련 법안 추진 중단 발표. [장관 발표](#) ([minister.infrastructure.gov.au](#))

한국에 필요한 일곱 가지 설계

비교 사례에서 도출한 제안 — 이미 시행 중인 제도 목록 아님

1 재원 다변화

정부·플랫폼·재단·언론·시민 후원 분산, 후원 비중·다년 조건 공개

2 지원과 편집의 분리

후원자가 검증 대상·판정·발행 시점에 개입 못 하는 계약·지배구조

3 공동 자료 기반

검증 기사·원자료·정정 이력 보존, 시점·권한 명시 후 재사용

4 공동 기술 인프라

한국어 중복 주장 탐지·전사·원자료 검색·출처 보존 도구 공동 개발
— 자동화의 공공재화

5 공개 평가

평균 정확도 외 고위험 오판·집단별 오류·유보 사유·정정 결과 공개

6 독립 감사와 피해 구제

이용자·검증 대상자가 근거를 내고 오류를 고칠 수 있는 절차

7 교육과 현장 취재

도구 교육 + 인터뷰·통계 해석·문서 확인 역량 투자

평가 질문

피해 구제가 빨라졌나, 허위정보 수익이 줄었나, 정당한 비판이
위축되지 않았나

공유 전 30초 — SIFT 네 동작

끝없이 조사하라는 뜻이 아니라, 짧게 출처를 판단하고 위험한 주장에 시간을 더 쓰는 방법 [Caulfield 2019](#)^①

S Stop · 멈춤

분노·공포·통쾌함이 강하면
공유부터 멈춤. 아는 것과 추측을
나눔

I Investigate · 출처 조사

새 탭에서 운영 주체·전문성·재원
·정정 기록 확인

F Find · 더 나은 보도

복제본 말고 독립 취재와 원자료
찾기

T Trace · 원래 맥락

잘린 영상·숫자·인용을 최초
문서와 앞뒤 문맥으로 되돌림

도구를 쓰는 순서

도구	용도	주의
Google Fact Check Explorer ^②	이미 발행된 팩트체크 검색	결과 없음 ≠ 사실·거짓
InVID-WeVerify ^③	영상 주요 프레임 추출, 이미지 검색	설명·날짜·장소는 추가 확인
Content Credentials ^④	서명된 제작·편집 정보 조사	이력 ≠ 내용의 진실
선관위·통계·법령·논문 원문	주장에 직접 대응하는 기록	기준일·수정 이력 확인

① **SIFT (Mike Caulfield)** Stop(멈춤) · Investigate the source(출처 조사) · Find better coverage(더 나은 보도) · Trace(원래 맥락 추적). 짧게 판단하고 위험한 주장에 시간을 더 쓰는 방법. [SIFT 원문 \(2019\)](#) (hapgood.us)

② **Google Fact Check Explorer** 전 세계 팩트체크 기관이 이미 발행한 검증 기사를 검색. 결과가 없다고 사실·거짓이 정해지는 것은 아님. [바로 가기](#) (toolbox.google.com)

③ **InVID-WeVerify 플러그인** 영상의 주요 프레임을 뽑아 역이미지 검색 등을 돕는 브라우저 확장 도구. [InVID 플러그인](#) (invid-project.eu)

④ **C2PA · Content Credentials** 사진·영상의 제작·편집 이력을 전자서명으로 붙여 전달하는 국제 표준임. 이력의 무결성은 확인하지만, 사진 속 사건이나 설명의 진실은 보장하지 않음. 이력이 없다고 가짜도 아님. [C2PA FAQ](#) (c2pa.org) [C2PA 설계 원칙](#) (c2pa.org)

숫자를 보면 여섯 가지를 묻음

1 분자와 분모

78.85%는 몇 건 중 몇 건?

2 단위

게시물·사람·신고·삭제 요청 중 무엇?

3 기간

하루·한 달·누적?

4 기준 시점

사건일과 발표일이 같은가?

5 정의

매출 vs 피해액, 평결 vs 실제 지급액

6 비교 가능성

조건이 다른 수치를 한 그래프에?

이미지·음성, 이렇게 확인함

- ❑ ‘1980년 신문’ 캡처 → 제호가 그때 있었나, 소장본에 그 지면이 있나 (AI 탐지보다 기록 대조가 빠름)
- ❑ ‘오늘 일어난 폭동’ 영상 → 프레임 추출·과거 사용 검색, 간판·언어·날씨 대조
- ❑ ‘가족이 납치됐다’ 전화 → 끊고, 저장해 둔 번호·다른 가족으로 확인. 상대가 준 번호로 걸지 않음 [금융위 안내](#)¹
- ❑ ‘의사가 보장하는 치료’ 광고 → 실존 인물·기관, 제품 허가·근거 따로 확인
- ❑ ‘특정 이민 집단의 범죄’ 게시물 → 수사기관 확인 신원인지, 미확인 캡처·타 지역 사건인지 분리

¹ 보이스피싱 대응 안내 (금융위원회) 의심하고, 끊고, 확인하기. 긴급 시 112·금융회사에 지급정지 요청, 금융 상담은 금융감독원 1332. 정책브리핑 안내 (korea.kr)

AI에게 검증을 제대로 묻는 법

다음 주장을 확인해 주세요. 검증 가능한 하위 주장으로 나누고, 발언일과 자료 기준일을 확인하세요. 각 주장에 직접 대응하는 원자료와 반대 근거를 제시하고, 저자·날짜·링크·근거 위치를 적어 주세요. 단순 인용 보도를 사실 확인 근거로 쓰지 마세요. 찾지 못했거나 읽지 못한 자료, 충돌하는 근거를 명시하세요. 근거가 부족하면 판정을 유보하고 필요한 추가 확인을 적어 주세요. 존재하지 않는 문헌·URL·인용문을 만들지 마세요.

복사해서 바로 쓰는 질문 틀

- ☐ 좋은 질문도 정확성을 보장하지 않음 → **AI 답변을 출처로 삼지 말고, 안내받은 원문을 직접 열어 봄**
- ☐ 링크 존재만 보지 않고 제목·날짜·주장·인용 위치까지 대조
- ☐ 속보(신원·사망자·동기)는 AI를 자료 정리 보조로만 사용, 단독 판정자로 삼지 않음 — ‘잠정’ 표시, 확인 전 공유 보류
- ☐ 두 출처가 같은 자료를 베꼈다면 ‘두 곳에서 확인’이 아님. 확신 없으면 ‘확인 중’으로 남김

9부 · 신고와 도움

피해를 봤다면 — 신고와 도움

상황	연락처	용도
보이스피싱·납치 사칭	112, 해당 금융회사 · 금융감독원 1332	범죄 신고, 지급정지 요청, 금융 상담 안내 ①
해킹·스미싱·개인정보 침해	한국인터넷진흥원 118	사이버 피해 상담·신고 안내 ②
선거법 위반·선거 딥페이크	선거관리위원회 1390	선거법 질의·신고제보
딥페이크 성범죄 등	디지털성범죄피해자지원센터 02-735-8994 · 1366(24시간)	상담·삭제지원·수사·법률 연계 온라인 신청 ③
식품·건기식 허위·과대광고	1399, 식품안전나라·지자체	광고 화면·판매자 정보 확보 안내 ④
온라인 협박· 명예훼손	경찰·해당 플랫폼 신고	URL·게시 시각·계정·화면 보존

2025년 보이스피싱 피해액 **1조 2,578억 원**(경찰청)은 보이스피싱 **전체** 집계 — ‘AI 딥페이크 피해 1조 원’으로 바뀌지 **않음** [SK텔레콤 뉴스룸](#) ⑤

① **보이스피싱 대응 안내** (금융위원회) 의심하고, 끊고, 확인하기. 긴급 시 112·금융회사에 지급정지 요청, 금융 상담은 금융감독원 1332. [정책브리핑 안내](#) (korea.or.kr)

② **한국인터넷진흥원 118** 해킹·스미싱·개인정보 침해 등 사이버 피해 상담·신고. [118 상담 안내](#) (kisa.or.kr)

③ **중앙디지털성범죄피해자지원센터** 02-735-8994, 1366(24시간). 상담·삭제지원·모니터링·수사·법률·의료 연계. [지원 신청 방법](#) (d4u.stop.or.kr)

④ **식품 허위·과대광고 신고 1399** 식품·건강기능식품 불량식품·허위광고 신고 전화. 모든 의료·의약품 광고의 공통 번호는 아님. [식품의약품안전처 안내](#) (mfds.go.kr) [식품안전나라](#) (foodsafetykorea.go.kr)

⑤ **2025 보이스피싱 피해액 (경찰청, SK텔레콤 뉴스룸)** 2025년 보이스피싱 피해액 1조 2,578억 원 — 보이스피싱 전체 집계. AI 사용 사건 비율과 피해액은 별도 집계 필요. [SK텔레콤 뉴스룸](#) (news.sktelecom.com)

예상 질문과 답변

질문	답변 요지
팩트체커도 편향되지 않나?	가능함. 그래서 선정 기준·원자료·재원·정정 이력 공개, 다른 검증자의 재현 가능성이 핵심
극우 사례가 많으면 편향?	공정성 = 모든 집단에서 같은 수의 오류 찾기가 아니라 같은 기준 적용. 사례 선정 이유와 자료 제시
AI가 사람보다 공정?	같은 규칙 반복은 장점. 그러나 학습자료·검색·프롬프트 영향 — 실제 오류 분포로 평가
100% 아니면 공개 불가?	확인 범위·불확실성·기준일을 명시해 공개 가능. 고위험 사안은 더 엄격한 검토·유보
팩트체크는 검열?	근거 공개로 반박하는 일 ≠ 삭제·차단 집행. 연결될 때는 권한·절차·불복 가능성 점검
탐지기로 끝낼 수 없나?	탐지 결과는 단서. 원본·맥락·기록·독립 확인과 결합
AI가 기사를 대체?	반복 탐색은 줄이지만 비공개 사실 취재·맥락 해석·반론·책임을 대신한다는 증거 없음
역사 논쟁은 모두 처벌?	아님. 법마다 대상·행위·고의·예외가 다름. 역사 연구의 검증과 처벌 요건 판단을 구분



맺으며

속도를 신뢰로 바꾸는 일

- ❑ 팩트체크의 목표 = 틀리지 않는 사람·기계의 선언이 아니라, 누구나 따라갈 수 있는 근거와 고칠 수 있는 절차
- ❑ AI = 더 많은 주장을 찾고 자료를 모으는 강력한 조력자 — 한국어에서도 가능성 확인
- ❑ 그 속도를 신뢰로 바꾸는 일 = 출처 확인·맥락 읽기·책임 있는 공개를 하는 사람과 제도의 몫
- ❑ 시민의 몫 = 공유 전 멈춤, 원문 확인, 모르면 ‘확인 중’

감사합니다 · 이종혁 · 경희대학교 미디어학과 · jongh1111@khu.ac.kr

핵심 기술 · 등장 3쪽 23쪽

RAG (검색 증강 생성)

AI가 답하기 전에 **웹·문서를 먼저 검색하고, 찾은 자료에 근거해** 답하게 하는 방식임. ‘기억으로 말하지 말고 자료 보고 말하라’는 지시와 같음. 자료를 붙여도 잘못 찾기·잘못 읽기·잘못 쓰기 오류는 남음.

➦ **AVeriTeC 2025 대회 논문** <https://doi.org/10.18653/v1/2025.fever-1.15>

➦ **ClaimCheck 논문(arXiv)** <https://doi.org/10.48550/arXiv.2510.01226>

논문 · 등장 5쪽 7쪽

Vosoughi, Roy & Aral (2018), Science

트위터 2006–2017년 약 **12만 6천 개** 확산 사례 분석. 거짓 뉴스가 참 뉴스보다 더 멀리·빠르게·길게 퍼졌고, 정치 분야에서 차이가 가장 컸음. 당시 트위터에서 판정 가능했던 사례에 한정된 결과.

➦ **Science 논문(DOI)** <https://doi.org/10.1126/science.aap9559>

보고서 · 등장 5쪽 7쪽

WEF 글로벌 리스크 보고서 2026

세계경제포럼의 위험 인식 조사. 허위·조작정보는 **향후 2년 위험 2위**. ‘AI 기술의 부정적 결과’는 2년 30위 → 10년 5위. 실제 피해액 순위가 아니라 응답자 인식.

➦ **Global Risks Report 2026** <https://www.weforum.org/publications/global-risks-report-2026/>

논문 · 등장 5쪽 20쪽

Porter & Wood (2021), PNAS

아르헨티나·나이지리아·남아공·영국 동시 실험, 22개 팩트체크 평가. 잘못된 믿음을 5점 척도에서 **최소 0.59점** 줄였고, 효과 대부분이 2주 넘게 유지.

➦ **PNAS 논문(DOI)** <https://doi.org/10.1073/pnas.2104235118>

논문 · 등장 5쪽 21쪽 33쪽

이중혁 (2026), 한국언론학보 70(2)

「한국어 팩트체크 필요성 탐지 모델 및 RAG 기반 팩트체크 자동화 시스템 개발: 대선 후보자 토론회 적용」. 토론 3,919문장 → 499건 선별, JTBC 56건 중 52건 포착(92.86%), 공통 52건 판정 일치 41건(78.85%), 가중 F1 79.04%.

➦ **DOI** <https://doi.org/10.20879/kjics.2026.70.2.003>

➦ **KCI 논문 정보** <https://www.kci.go.kr/kciportal/ci/sereArticleSearch/ciSereArtiView.kci?sereArticleSearchBean.artiId=ART003331812>

➦ **탐지 모델 (Hugging Face)** https://huggingface.co/jonghhhh/claim_fac_tcheck

보고서 · 등장 6쪽

정보 무질서 (Wardle & Derakhshan, 2017)

유럽평의회 보고서. 오정보·허위조작정보·악의적 정보를 **진위와 의도** 두 축으로 구분한 대표 틀.

➦ **Council of Europe 보고서 (PDF)** <https://rm.coe.int/information-disorder-toward-an-interdisciplinary-framework-for-researc/168076277c>

국제기구 · 등장 6쪽

인포데믹 (WHO)

감염병 유행 중 온·오프라인에서 정보가 지나치게 많아지는 현상. 그 안에 거짓·오도 정보가 섞여 혼란과 위험 행동을 부름.

➦ **WHO: Infodemic** <https://www.who.int/health-topics/infodemic>

개념 · 등장 7쪽

거짓말쟁이의 배당 (liar’s dividend)

조작물이 흔해질수록 **진짜 증거도 ‘AI 조작’**이라며 부인하기 쉬워지는 현상임. Chesney-Citron이 제시한 개념.

➦ **Chesney & Citron (2019) 논문** <https://doi.org/10.15779/Z38RV0015J>

논문 · 등장 8쪽

이란 메탄올 중독 (Critical Care, 2020)

2020년 2월 23일–5월 2일 메탄올 중독 입원 **5,876건**, 법의학기관 집계 사망 **800명**(병원 내 사망 534명). 술·소독제가 코로나를 막는다는 거짓 믿음이 배경으로 지적됨.

➦ **Hassanian-Moghaddam 등 (2020)** <https://doi.org/10.1186/s13054-020-03140-w>

보도 · 등장 8쪽

인도 WhatsApp 납치범 소문 (2018)

아동 납치범이 돌아다닌다는 WhatsApp 메시지 확산 후 무고한 행인들이 집단폭행당해 숨진 사건 잇따름. 2018년 7월 카르나타카 32세 남성 사망 사건 관련 25명 체포.

➦ **Reuters/Euronews 보도** <https://www.euronews.com/2018/07/15/india-n-police-arrest-25-in-latest-whatsapp-rumour-led-lynching>

팩트체크 · 등장 8쪽

슬로바키아 선거 직전 조작 음성 (2023)

총선 이틀 전, 진보슬로바키아 대표 미할 시메치카와 Denník N 기자 모니카 토도바가 선거 조작을 논의하는 듯한 음성 유통. AFP가 조작 징후를 검증.

➦ **AFP Fakty(슬로바키아어)** <https://fakty.afp.com/doc.afp.com.33WY9LF>

정부 발표 · 등장 8쪽

FCC — 바이든 사칭 딥페이크 자동전화 (2024)

뉴햄프셔 예비선거 직전 바이든 복제 음성으로 투표를 미루라고 유도한 자동전화. 2024년 9월 26일 FCC가 정치 컨설턴트에게 **600만 달러** 과징금 부과.

➦ **FCC 보도자료 (PDF)** <https://docs.fcc.gov/public/attachments/D0C-405811A1.pdf>

정부 발표 · 등장 8쪽

홍콩 딥페이크 화상회의 사기 (2024)

직원이 딥페이크로 꾸민 ‘본사 재무책임자’ 화상회의에 속아 약 **2억 홍콩달러**를 송금. 공개 영상으로 미리 만든 합성 자료 이용.

➦ **홍콩 정부 LCQ9 답변** <https://www.info.gov.hk/gia/general/202406/26/P2024062600192.htm>

보도 · 등장 9쪽

딥페이크 삭제 요청 1만 건 (경향신문, 2026.5.28)

2026 지방선거 관련 딥페이크 게시물 삭제 요청 **10,319건**(5월 27일 기준). 2025 대선 4.4–6.3 집계 10,510건의 98.2% 수준. 기간이 달라 증가를 계산에는 부적합.

➦ **경향신문 기사** <https://www.khan.co.kr/article/202605281700001>

보도 · 등장 9쪽

AI 가짜 앵커·딥페이크와 선관위 (경향신문, 2026.5.25)

예비후보를 해의 시사지가 선정했다는 식의 가짜 뉴스 앵커 영상 등, 대중화된 AI로 쉽게 만들어지는 선거 허위정보와 선관위 대응.

➦ **경향신문 기사** <https://www.khan.co.kr/article/202605251646001>

법·제도 · 등장 9쪽

공직선거법 딥페이크 규정

선거일 전 90일부터 선거일까지 선거운동 목적의 딥페이크 영상 등 제작·편집·유포·상영·게시 금지. 그 밖의 기간에도 가상정보 표시 의무, 허위사실 공표 규정 등 적용.

➦ **중앙선관위 보도자료 (2025.4.23)** <https://img.nec.go.kr/cmm/dozen/view.do?bcIdx=275312&cbIdx=1090&fileNo=2>

보고서 · 등장 10쪽

디지털 뉴스 리포트 2026 — 한국

로이터저널리즘연구소 온라인 설문. 한국 유튜브 뉴스 이용 **49%**(48개 시장 평균 31%), 뉴스 신뢰 30%, 온라인 허위정보 우려 59%, AI 챗봇 뉴스 이용 14%. 한국 파트는 한국언론진흥재단 연구진 집필.

➦ **Reuters Institute 한국 페이지** <https://reutersinstitute.politics.ox.ac.uk/digital-news-report/2026/south-korea>

➦ **뉴스is 보도** https://www.newsis.com/view/NISX20260616_0003671612

보도 · 등장 11쪽

은혜의강 교회 소금물 분무 (2020)

성남 은혜의강 교회가 코로나 예방 명목으로 같은 분무기로 교인들 입에 소금물을 뿌린 사실 확인. 방역당국은 감염 확산 영향 가능성 지적.

➦ **연합뉴스 보도** <https://www.yna.co.kr/view/AKR20200316134900061>

보도 · 등장 11쪽

유튜브 ‘AI 가짜 의사’ 광고 (서울신문, 2026.6.10)

AI로 만든 의사가 식품 효능을 홍보. 업체가 약 9개월간 약 65만 개 판매, **매출 81억 원** 혐의로 수사. 매출액이지 확정 피해액 아님.

➦ **서울신문 기사** <https://www.seoul.co.kr/news/society/accident/2026/06/10/20260610500181>

팩트체크 · 등장 12쪽

‘선거연수원 중국인 99명 체포’ 선관위 팩트체크

당시 선거연수원 숙박자는 **교육 참여 공무원 88명과 외부 강사 8명 등 총 96명**. 체포설은 전부 허위라고 설명.

➦ **중앙선관위 팩트체크 (2025.1.23)** <https://www.nec.go.kr/site/nec/ex/bs/View.do?bcIdx=265865&cbIdx=1147>

판결 · 등장 12쪽

헌법재판소 2024헌나8 (2025.4.4)

대통령 탄핵 결정. 의혹이 있다는 것만으로 중대한 위기상황이 현실적으로 발생했다고 볼 수 없고, 부정선거 의혹은 **정치적·제도적·사법적** 수단으로 해결할 문제라고 판단.

➤ **헌법재판소 선고요지** <https://www.ccourt.go.kr/site/kor/ex/bbs/View.do?bcIdx=4243345&cbIdx=1195>

보고서 · 등장 13쪽

미 하원 1·6 조사위원회 최종보고서 (2022)

2020 대선 부정 주장, 결과 뒤집기 시도, 2021년 1월 6일 의회 공격까지의 경과 정리.

➤ **최종보고서 (PDF)** <https://www.govinfo.gov/content/pkg/GPO-J6-REPORT/pdf/GPO-J6-REPORT.pdf>

보고서 · 등장 13쪽

영국 하원 내무위원회 — 2024 여름 소요 (2025.4.14)

사우스포트 아동 살해 직후 “범인은 망명 신청자”라는 추측·오정보가 온라인에서 폭력 선동에 중요한 역할을 했다는 내무부 설명 수록. 모스크·망명 신청자 속소 공격 기록. 위원회는 허위정보가 소요의 구체적 동인이었던 정도는 불분명하다고도 지적.

➤ **HC 381 보고서** <https://publications.parliament.uk/pa/cm5901/cmselect/cmhaiff/381/report.html>

팩트체크 · 등장 13쪽

스프링필드 ‘반려동물 먹는 이민자’ 주장 (PolitiFact)

2024 대선 토론에서 반복된 오하이오 스프링필드 아이티 이민자 주장 — 현지 경찰·시 당국에 신뢰할 만한 보고 없음.

➤ **PolitiFact 팩트체크** <https://politifact.com/factchecks/2024/sep/11/donald-trump/trump-repeats-baseless-claims-that-haitian-immigrants-eat-pets/>

보고서 · 등장 13쪽

크라이스트처치 모스크 테러 왕립조사위 (2020)

2019년 테러를 이해하기 위해 백인우월주의·반이민·반무슬림 사상·우익 극단주의·온라인 급진화 맥락 검토.

➤ **왕립조사위 보고서 해당 장** <https://christchurchattack.royalcommission.nz/the-report/part-2-context/harmful-behaviours-right-wing-extremism-and-radicalisation>

보도 · 등장 14쪽

5·18 왜곡 AI 가짜 신문

1980년 5월 20일자 ‘광주일보’처럼 꾸민 합성 지면에 ‘북한군 투입·무기고 탈취’ 주장. 5·18기념재단 고소, 경찰이 20대 제작자 등 검거(수사 단계). ‘광주일보’는 1980년 12월 언론 통폐합으로 처음 발행된 제호.

➤ **연합뉴스 (2026.5.27)** <https://www.yna.co.kr/view/AKR20260527078100054>

➤ **뉴스스 (2026.7.6)** https://www.newsis.com/view/NISX20260706_0003697961

보도 · 등장 14쪽

지만원 징역 2년 확정 (2023.1.12)

5·18 사진 속 시민들을 ‘북한 특수군’으로 지목해 명예를 훼손한 혐의 등으로 대법원이 징역 2년 확정.

➤ **연합뉴스 보도** <https://www.yna.co.kr/view/AKR202301121070000054>

보도 · 등장 14쪽

5·18진상규명조사위 — 북한군 침투설 ‘허위’ (2024.4)

지만원이 제시한 ‘결정적 증거 42개’를 검토해 모두 사실무근으로 결론. 사진 판독 오류와 제한된 군사 지식에 기반 추론이라고 지적.

➤ **뉴스스 보도** https://www.newsis.com/view/NISX20240402_0002685461

보도 · 등장 15쪽

참사 피해자 겨냥 허위글 3천 건 (2026.5)

세월호·이태원·제주항공 참사 희생자·유족을 겨냥한 허위·모욕 글 약 3천 건을 올린 50대 구속. 한 피의자에 대한 수사 내용.

➤ **뉴스스 보도** https://www.newsis.com/view/NISX20260530_0003650326

법·제도 · 등장 15쪽

개정 위안부피해자법 (2026.6.11 시행)

일본군 ‘위안부’ 피해 허위사실 유포에 **최대 징역 5년 또는 벌금 5천만 원**. 예술·학문·연구·보도 등 정당한 목적의 활동은 처벌 제외.

➤ **정책브리핑 (성평등가족부)** <https://www.korea.kr/news/policyNewsView.do?newsId=148966277>

판결 · 등장 15쪽

샌디훅 부정론 — 알렉스 존스 배상

2022년 코네티컷 배심원 **9억 6,500만 달러** 판결, 판사가 약 4억 7,300만 달러 추가. 2024년 12월 항소법원은 판결을 유지하고 1억 5천만 달러(CUTPA) 부분만 파기.

➤ **Connecticut Public (2022)** <https://www.ctpublic.org/news/2022-11-110/alex-jones-ordered-to-pay-473m-more-to-sandy-hook-families>

➤ **AP/Connecticut Public (2024)** <https://www.ctpublic.org/news/2024-12-06/connecticut-court-upholds-965-million-verdict-against-alex-jones>

보고서 · 등장 15쪽

홀로코스트 기억과 생성형 AI

UNESCO: 생성형 AI가 존재하지 않는 사건·인용을 만들거나 부정론을 증폭할 위험 경고. 아우슈비츠 기념관: AI 생성 수용소·희생자 이미지 확산 문제 제기.

➤ **UNESCO (2024)** <https://www.unesco.org/en/articles/new-unesco-report-warns-generative-ai-threatens-holocaust-memory>

➤ **Auschwitz Memorial report 2025 (PDF)** https://www.auschwitz.org/gfx/auschwitz/userfiles/_public/2026_news/report_2025.pdf

국제 기록 · 등장 15쪽

로항야·르완다·스레브레니차

유엔 미얀마 독립조사기구: 군 연계 Facebook 혐오 네트워크 분석. 르완다 국제형사재판소(2003): 미디어 책임자들의 집단학살 관련 유죄. 구유고 국제형사재판소(2004): 크르스티치 항소심에서 스레브레니차 집단학살 확인.

➤ **IImm 분석 보고서** <https://iimm.un.org/en/publication-iimm-analytical-reports>

➤ **ICTR ‘미디어 재판’** <https://unictr.irmct.org/en/news/three-media-leaders-convicted-genocide>

➤ **ICTY 크르스티치 항소심** <https://www.icty.org/en/press/appeals-chamber-judgement-case-prosecutor-v-radislav-krstic>

기관 · 등장 17쪽

FactCheck.org

2003년 출범한 미국 비영리 팩트체크 매체. 검증 절차를 공개하고, Meta 제3자 팩트체크 제휴(2016.12–2025.4) 내역도 명시.

➤ **15주년 글 (2018)** <https://www.factcheck.org/2018/12/our-15th-anniversary/>

➤ **검증 절차 (Our process)** <https://www.factcheck.org/our-process/>

기관 · 등장 17쪽

PolitiFact

2007년 출범. ‘진실 측정기(Truth-O-Meter)’ 등급으로 유명하며 2009년 풀리처상 수상.

➤ **풀리처상 수상 (2009)** <https://politifact.com/article/2009/apr/20/politifact-wins-pulitzer/>

보도 · 등장 17쪽 47쪽

SNU팩트체크 (2017–2024)

2017년 3월 29일 12개 언론사와 출범, 약 30개 제휴사·약 5천 건 검증 축적. 2023년 GlobalFact 10 서울 공동 개최. 재원 중단으로 2024년 8월 18일부터 무기한 휴지, 기존 자료는 읽기 전용.

➤ **오마이뉴스 보도 (2024.8.19)** https://www.ohmynews.com/NWS_Web/View/at_pg.aspx?CNTN_CD=A0003055180

국제 기준 · 등장 18쪽

IFCN 원칙 강령

국제팩트체킹네트워크의 5대 약속: 비당파성·공정성, 출처 투명성, 재원·조직 투명성, 방법론 투명성, 공개적이고 정직한 정정.

➤ **IFCN Code of Principles** <https://ifcncodeofprinciples.poynter.org/the-commitments>

데이터셋 · 등장 19쪽 34쪽

LIAR 판정 척도

PolitiFact 기사로 만든 연구용 데이터셋의 6등급: true, mostly-true, half-true, barely-true, false, **pants-fire**(새빨간 거짓말). ‘판단 유보’ 등급은 없음. 이종혁 (2026)은 이를 응용해 판단 유보를 포함한 6단계 사용.

보고서 · 등장 20쪽

Duke Reporters’ Lab 2026 팩트체크 센서스

2026년 6월 1일 기준 116개국·70개 언어 **437개** 프로젝트 활동. 2025년 말 441개에서 감소 — 재원 압박 속에서도 대부분 존속.

↗ **2026 census** <https://reporterslab.org/2026/06/12/2026-census-fact-checking-losses-continue-amid-funding-pressure-but-most-projects-persist/>

용어 · 등장 20쪽

ClaimReview

팩트체크 대상 주장과 검증 결과를 기계가 읽을 수 있게 적는 **구조화 데이터 형식**임. 2025년 Google이 검색 결과 표시를 정리했지만, 형식 자체나 팩트체크 기사가 폐지된 것은 아님.

↗ **Google Search Central 블로그 (2025.6)** <https://developers.google.com/search/blog/2025/06/simplifying-search-results>

시스템 · 등장 22쪽 25쪽 26쪽

ClaimBuster (텍사스대 알링턴)

토론·연설 문장의 ‘검증 가치’를 점수화한 선구적 시스템. 2017년 논문은 모니터링 → 검증 가치 평가 → 기존 검증 매칭 → 검증·보고의 end-to-end 구조 제시.

↗ **Hassan 등 (2017) 논문** <https://doi.org/10.14778/3137765.3137815>

용어 · 등장 22쪽

판단 유보

근거·맥락이 충분하지 않을 때 결론을 보류하는 기능임. ‘모름’을 숨기지 않고 **왜 모르는지**(검색 실패·자료 비공개·출처 충돌)를 밝히는 것도 검증의 일부.

핵심 기술 · 등장 23쪽

LLM (대규모 언어모델)

방대한 글로 학습해 문장을 이해·생성하는 AI(예: ChatGPT, Gemini, Claude)임. 학습한 지식으로 답하기도 하고, 검색·데이터베이스를 **도구**로 연결해 최신 자료를 읽기도 함.

용어 · 등장 23쪽 45쪽

환각 (hallucination)

자료에 없는 내용·출처·인용문을 **사실처럼** 지어내는 오류임. 존재하지 않는 판결·논문·URL 생성이 대표적. 대응 = 실제 본문·DOI·인용 위치 대조.

시스템 · 등장 25쪽 27쪽

Squash (Duke Reporters’ Lab)

연설을 실시간 전사하고 관련 팩트체크를 찾아 화면에 띄운 시스템. 전사 오류·영동한 매칭·**비교할 기존 검증 부족**이 주요 장애물.

↗ **Poynter 회고 (2021)** <https://www.poynter.org/fact-checking/2021/the-lessons-of-squash-the-first-automated-fact-checking-platform/>

시스템 · 등장 26쪽

ClaimCheck (2025, 프리프린트)

작은 공개 모델 Qwen3-4B와 웹 검색을 결합. 검색 계획 → 근거 수집 → 종합 → 추가 검색 → 판정. 저자 보고 AVeriTeC 자료 정확도 76.4%.

↗ **arXiv 논문** <https://doi.org/10.48550/arXiv.2510.01226>

시스템 · 등장 28쪽

Full Fact AI (영국)

평일 약 33만 문장 처리, 30개국 40개 이상 기관 이용(2025 공개). 반복 주장 탐지, 팟캐스트 속 허위정보 구간 찾기, 잘못된 보도 포착 → 정정 유도.

↗ **How AI can help fact checkers (2025)** <https://fullfact.ai/blog/how-ai-can-help-fact-checkers/>

↗ **Full Fact AI 홈** <https://fullfact.ai/>

보도 · 등장 28쪽

Full Fact의 2026 선거 대응 (Nieman Lab)

스코틀랜드·웨일스 의회, 잉글랜드 시장 선거 후보 관련 계정 1천여 개 모니터링. 이미지·영상 16,514건 중 SynthID 흔적으로 보이는 136건 발견.

↗ **Nieman Lab (2026.6.25)** <https://www.niemanlab.org/2026/06/full-fact-is-battling-ai-generated-elections-content-with-ai-tools-of-its-own/>

시스템 · 등장 28쪽

Full Fact AI 제품 기능

정확성에 대한 AI 예비 판정과 **100점 만점 위해 점수** 등을 설명. 예비 판정 기능 = 사람 검토 보조.

↗ **제품 페이지** <https://fullfact.ai/product/>

용어 · 등장 28쪽

SynthID

Google이 자사 AI 생성물에 넣는 **보이지 않는 워터마크**임. 찾으면 해당 도구 사용의 단서가 되지만, 다른 도구로 만든 AI 콘텐츠는 잡지 못함.

시스템 · 등장 29쪽

Factiverse × 덴마크 Tjekdet (2024)

토론 실시간 검증: 전사 → 주장 탐지 → 다중 검색. 음성 경로가 영상 스트림보다 최대 30초 빠름(개발사). 전사 정확도 약 95%는 Tjekdet 편집장의 평가.

↗ **Factiverse 회고** <https://www.factiverse.ai/blog/our-takeaways-from-the-worlds-first-real-time-fact-checking-service>

시스템 · 등장 29쪽

Factiverse × 스웨덴 SVT (2026)

유튜브 등 정치 콘텐츠를 모니터링해 편집자에게 요약 제공. ‘하루 120시간’은 개발사가 추정한 선거기 정치 영상 규모.

↗ **Factiverse 사례 글** <https://www.factiverse.ai/blog/how-svt-can-now-see-every-story-before-it-breaks>

시스템 · 등장 29쪽

Factiverse 헝가리 총선 분석 (2026)

주요 정당·후보 진영 5곳의 영상 62개에서 1시간 30분 이내 2,528개 주장 추출·분석(개발사 보고).

↗ **Factiverse 분석 글** <https://www.factiverse.ai/blog/hungary-2026-map-ping-a-fractured-political-landscape>

시스템 · 등장 30쪽

Chequeabot (Chequeado, 아르헨티나)

발언·보도에서 검증 후보를 찾고 기자의 선정을 도움. 전사 시간 90% 감소 등 보고.

↗ **Poynter 기고 (2024)** <https://www.poynter.org/commentary/2024/how-fact-checkers-can-use-ai-wisely/>

시스템 · 등장 30쪽

Meedan Check

메신저 제보 수집, 유사 주장·이미지 대조로 검증 작업·회신 지원. 2019 인도 총선 Checkpoint 프로젝트에 사용.

↗ **Meedan #TechAndCheck 2020** <https://meedan.com/post/tech-and-check-2020>

시스템 · 등장 30쪽

Fátima (Aos Fatos, 브라질)

자사 검증 기사에 기반해 질문에 답하는 챗봇. 초기 시험 답변 94% 적절(운영자 설명).

↗ **Aos Fatos: Fátima** <https://www.aosfatos.org/fatima/>

↗ **Nieman Lab (2024)** <https://www.niemanlab.org/2024/01/this-brazilian-fact-checking-org-uses-a-chatgpt-esque-bot-to-answer-reader-questions/>

시스템 · 등장 30쪽

Snopes FactBot

Cal Poly와 Snopes가 공동 개발. Snopes 기사 자료를 대화형으로 검색해 답함.

↗ **Cal Poly 발표 (2024)** <https://www.calpoly.edu/news/cal-poly-and-snopes-develop-ai-service-fact-check-your-questions>

사례 · 등장 31쪽

Der Spiegel AI 팩트체크 (2024 베타)

자사 원고의 사실 주장 추출 → 자료 확인 → 신뢰도 점수·경보 → 사람 후속 검토. 베타 단계 실험.

↗ **ONA 사례 연구** <https://www.journalists.org/news/case-study-enhancing-fact-checking-with-ai-at-der-spiegel>

보고서 · 등장 31쪽

AI 작성 Community Notes (R Street, 2026)

2025.9–2026.3 노트 423,915개 중 활동 AI 계정 24개가 쓴 31,464개(7.4%).

‘도움됨’ 도달률 AI 18.0%, 인간 8.9%.

↗ **R Street 보고서** <https://www.rstreet.org/research/ai-writers-on-community-notes-an-evaluation-of-seven-months-of-data/>

도구 · 등장 32쪽

Backstory (Google DeepMind)

이미지의 맥락·과거 사용·생성/편집 단서를 조사하는 실험 도구. 2026년 8월 보도 당시 신뢰 테스트에게만 제공. 기자 시험에서 기자 본인 사진을 다른 기자로 오인한 사례 보고.

↗ **DeepMind 블로그** <https://deepmind.google/blog/exploring-the-context-of-online-images-with-backstory/>

↗ **Nieman Lab (2026.8.19)** <https://www.niemanlab.org/2026/08/googles-new-ai-tool-helps-fact-checkers-investigate-ai-fakes/>

공개 모델 · 등장 33쪽

jonghhhh/claim_factcheck

이종혁(2026) 연구의 한국어 검증 필요 문장 탐지 모델 공개 페이지임.

↗ **Hugging Face 모델 페이지** https://huggingface.co/jonghhhh/claim_factcheck

모델 · 등장 34쪽

KcELECTRA

네이버 뉴스 댓글 등 구어체 한국어로 학습한 공개 언어모델임. 이종혁(2026)의 ‘검증 필요 문장’ 탐지 모델의 기반.

↗ **Hugging Face: KcELECTRA** <https://huggingface.co/beomi/KcELECTRA-base-v2022>

국제 대회 · 등장 34쪽 41쪽

CLEF CheckThat!

유럽 CLEF 학회의 자동 팩트체크 공동과제임. 검증 가치 탐지, 숫자·시간 주장 검증, 팩트체크 기사 생성 등을 다룸. 이종혁(2026)은 이 자료를 번역해 탐지 모델 학습에 사용.

↗ **CheckThat! 2026 개요 (arXiv)** <https://doi.org/10.48550/arXiv.2602.09516>

↗ **CheckThat! Lab 홈페이지** <https://checkthat.gitlab.io/>

도구 · 등장 34쪽

LangGraph

여러 AI 작업 단계(검색 → 정리 → 판정 → 재검색)를 흐름도처럼 연결해 실행하는 개발 도구임.

↗ **LangGraph (GitHub)** <https://github.com/langchain-ai/langgraph>

평가 용어 · 등장 35쪽

정밀도 (precision)

시스템이 ‘검증 필요’라고 고른 것 중 실제로 맞은 비율임. 높을수록 헛짚는 일이 적음.

평가 용어 · 등장 35쪽

재현율 (recall)

실제 검증이 필요한 문장 중 시스템이 찾아낸 비율임. 75%면 4개 중 1개를 놓친 셈.

평가 용어 · 등장 35쪽

F1 점수

정밀도와 재현율의 조화평균임. 한쪽만 높고 다른 쪽이 낮으면 F1이 낮아져 균형을 보여 줌.

평가 용어 · 등장 38쪽 41쪽

시간적 누출 · 지식 누출

평가 시점 이후에 나온 자료나 정답 기사(기존 팩트체크)가 검색·학습에 섞여 성능을 부풀리는 문제임. 시험 문제를 미리 본 것과 같은 효과.

↗ **CLEF CheckThat! 2026 개요** <https://doi.org/10.48550/arXiv.2602.09516>

용어 · 등장 39쪽 45쪽

자동화 편향

사람 검토자가 그럴듯한 AI 초안을 충분히 따져 보지 않고 승인하는 경향임. 대응 = 일부 사례 독립 재검토, 반증 담당 지정, 정정 기록.

블로그 · 등장 39쪽

Full Fact AI 해커톤 (2026.3)

하루 동안 초기 조사, 편집 지침 점검 등 AI 시제품 12개 제작.

↗ **Full Fact AI 블로그** <https://fullfact.ai/blog/ai-playgroup-hackathon/>

평가 용어 · 등장 42쪽

혼동행렬

실제 범주와 예측 범주의 조합별 결과표임. ‘거짓을 참으로’ 같은 치명적 오판이 몇 건인지 드러남.

평가 용어 · 등장 42쪽

보정 (calibration)

시스템이 말하는 확신도와 실제 정답 빈도가 맞는 정도임. ‘90% 확신’한 답이 실제로 90% 맞아야 잘 보정된 것.

데이터셋 · 등장 43쪽

AVeriTeC (2023)

50개 팩트체크 기관이 다룬 현실 주장 4,568개와 웹 근거로 구성된 평가 자료. 인위적 문장 평가의 한계를 줄이려는 목적.

↗ **NeurIPS 논문 (DOI)** <https://doi.org/10.52202/075280-2842>

국제 대회 · 등장 43쪽

제2회 AVeriTeC 공동과제 (FEVER 2025)

공개 가중치 모델·단일 GPU 23GB·주장당 평균 1분 이내 조건. 7개 제출 중 최고 33.17 — 판정과 근거 품질을 함께 충족해야 인정되는 결합 점수. HerO 효율화 버전이 기준 시스템.

↗ **Akhtar 등 (2025)** <https://doi.org/10.18653/v1/2025.fever-1.15>

시스템 · 등장 43쪽

HerO

한국 연구진(송실대)이 개발한 공개 자동 팩트체크 시스템임. 2025년 AVeriTeC 대회에서 계산 효율화 버전이 공식 기준 시스템으로 쓰임.

↗ **GitHub: HerO** <https://github.com/ssu-humane/HerO>

↗ **AVeriTeC 2025 대회 논문** <https://doi.org/10.18653/v1/2025.fever-1.15>

조사 · 등장 44쪽

EBU·BBC AI 뉴스 답변 국제 조사 (2025)

18개국 22개 공영미디어, 14개 언어, 3천여 응답 평가. 45% 중대한 문제 1개 이상, 31% 심각한 출처 문제, 20% 주요 정확성 문제.

↗ **EBU 발표** <https://www.ebu.ch/news/2025/10/ai-s-systemic-distortion-of-news-is-consistent-across-languages-and-territories-international-study-by-public-service-broadcasters>

논문 · 등장 44쪽

DeVerna 등 (2024), PNAS

미국 2,159명, 정치 헤드라인 40개 실험. LLM 팩트체크는 진위 식별력을 유의하게 높이지 못했고 일부 조건에서 오히려 해침. 인간 팩트체크는 개선.

↗ **PNAS 논문 (DOI)** <https://doi.org/10.1073/pnas.2322823121>

프리프린트 · 등장 44쪽

“@Grok is this true?” (Renault 등, 2026)

X에서 Grok·Perplexity에 요청된 사실 확인 150만여 건과 실험 분석. 표본 게시물 판정 일치: Grok 54.5%, Perplexity 57.7%, 팩트체커 간 64.0%. 동료 심사 전 프리프린트.

↗ **PsyArXiv (DOI)** https://doi.org/10.31234/osf.io/85quw_v3

출처 증명 · 등장 46쪽 50쪽

C2PA · Content Credentials

사진·영상의 제작·편집 이력을 전자서명으로 붙여 전달하는 국제 표준임. 이력의 무결성은 확인하지만, 사진 속 사건이나 설명의 진실은 보장하지 않음. 이력이 없다고 가짜도 아님.

↗ **C2PA FAQ** <https://c2pa.org/faqs/>

↗ **C2PA 설계 원칙** <https://c2pa.org/principles/>

보고서 · 등장 47쪽

국회입법조사처 — 2023 국정감사 이슈 분석

팩트체크넷의 2023년 2월 법인 해산·플랫폼 운영 중단 경과 등 수록.

↗ **국회입법조사처 자료 (PDF)** https://www.shinkim.com/newsletter/2023/A/2023_vol198/links/2023_vol198_322.pdf

↗ **국회입법조사처 홈** <https://www.nars.go.kr/>

법·제도 · 등장 47쪽

정보통신망법 가이드라인 (2026.7.8)

개정법 2026.1.6 공포, 7.7 시행. 수익형 게재자 가중배상 최대 5배, 과징금 최대 10억 원, 대규모 플랫폼 의무, 팩트체크 단체와 협약 체결 가능, 독립성·남용 방지 규정.

↗ **방송미디어통신위원회 가이드라인** <https://www.kmcc.go.kr/download.do?fileSeq=71297>

법·제도 · 등장 48쪽

EU 허위정보 행동강령

2025년 2월 DSA(디지털서비스법) 체계의 행동강령으로 통합 승인, 7월 1일부터 약속 이행 감사 가능.

↗ **European Commission** <https://digital-strategy.ec.europa.eu/en/library/code-conduct-disinformation>

지원 제도 · 등장 48쪽

EU 독립 팩트체크 500만 유로 지원 (2026)

유럽 민주주의 방패 차원의 지원. EFCSN의 FACTEUR는 30개월 사업, 60% 초과 금액을 팩트체크 기관에 배분.

↗ **European Commission 발표** <https://digital-strategy.ec.europa.eu/en/news/commission-boosts-independent-fact-checking-eu5-million-grant-under-european-democracy-shield>

↗ **EFCSN FACTEUR** <https://efcsn.com/funding-opportunities/efcsn-eu-grant-facteur/>

보고서 · 등장 48쪽

OECD, Facts not Fakes (2024)

정보 무결성을 위한 통합 접근: 정보원의 투명성·책임성·다원성, 사회적 회복력, 제도와 거버넌스.

↗ **OECD 보고서 (DOI)** <https://doi.org/10.1787/d909ff7a-en>

기관 · 등장 48쪽

일본 팩트체크센터 (JFC) 재원 공개

2025 회계연도(2025.4~2026.3) 수입 26,172,407엔, 지출 33,478,977엔, 부족액 7,306,570엔은 이월금으로 충당. Google-LY·Meta-IFCN 보조금 합계 21,673,341엔.

↗ **JFC funding and budget** <https://www.factcheckcenter.jp/funding-en/>

법·제도 · 등장 48쪽

싱가포르 POFMA

장관이 정정 등 지시를 내리는 구조. 변경·취소 신청과 고등법원 불복 절차 존재.

↗ **POFMA Office FAQ (PDF)** <https://www.pofmaoffice.gov.sg/files/documents/pofma-office-faqs.pdf>

법·제도 · 등장 48쪽

호주 허위정보 법안 철회 (2024.11.24)

상원 지지를 확보하지 못해 허위정보 관련 법안 추진 중단 발표.

↗ **장관 발표** <https://minister.infrastructure.gov.au/rowland/media-release/communications-legislation-amendment-combatting-misinformation-and-disinformation-bill-2024>

방법 · 등장 50쪽

SIFT (Mike Caulfield)

Stop(멈춤)· Investigate the source(출처 조사)· Find better coverage(더 나은 보도)· Trace(원래 맥락 추적). 짧게 판단하고 위험한 주장에 시간을 더 쓰는 방법.

↗ **SIFT 원문 (2019)** <https://hapgood.us/2019/06/19/sift-the-four-moves/>

도구 · 등장 50쪽

Google Fact Check Explorer

전 세계 팩트체크 기관이 이미 발행한 검증 기사를 검색. 결과가 없다고 사실·거짓이 정해지는 것은 아님.

↗ **바로 가기** <https://toolbox.google.com/factcheck/explorer>

도구 · 등장 50쪽

InVID-WeVerify 플러그인

영상의 주요 프레임을 뽑아 역이미지 검색 등을 돕는 브라우저 확장 도구.

↗ **InVID 플러그인** <https://www.invid-project.eu/tools-and-services/invid-verification-plugin/>

정부 안내 · 등장 51쪽 53쪽

보이스피싱 대응 안내 (금융위원회)

의심하고, 끊고, 확인하기. 긴급 시 112·금융회사에 지급정지 요청, 금융 상담은 금융감독원 1332.

↗ **정책브리핑 안내** <https://www.korea.kr/news/policyNewsView.do?newsId=148922419>

기관 · 등장 53쪽

한국인터넷진흥원 118

해킹·스미싱·개인정보 침해 등 사이버 피해 상담·신고.

↗ **118 상담 안내** <https://www.kisa.or.kr/303>

기관 · 등장 53쪽

중앙디지털성범죄피해자지원센터

02-735-8994, 1366(24시간). 상담·삭제지원·모니터링·수사·법률·의료 연계.

↗ **지원 신청 방법** <https://d4u.stop.or.kr/ko/support/content/guide>

기관 · 등장 53쪽

식품 허위·과대광고 신고 1399

식품·건강기능식품 불량식품·허위광고 신고 전화. 모든 의료·의약품 광고의 공통 번호는 아님.

↗ **식품의약품안전처 안내** https://www.mfds.go.kr/brd/m_74/view.do?company_cd=&company_nm=&itm_seq_1=0&itm_seq_2=0&multi_itm_seq=0&page=215&seq=30636&srchFr=&srchTo=&srchTp=&srchWord=

↗ **식품안전나라** <https://www.foodsafetykorea.go.kr/>

자료 · 등장 53쪽

2025 보이스피싱 피해액 (경찰청, SK텔레콤 뉴스룸)

2025년 보이스피싱 피해액 1조 2,578억 원 — 보이스피싱 전체 집계. AI 사용 사건 비율과 피해액은 별도 집계 필요.

↗ **SK텔레콤 뉴스룸** <https://news.sktelecom.com/221425>